

Detecção de fadiga em idosos utilizando séries temporais

Enzo Ramon Campa¹, Jasmini Rebecca Gomes dos Santos¹, Leandro Ceron Durau¹

¹Programa de Graduação em Ciência da Computação

Pontifícia Universidade Católica do Paraná (PUCPR)

Caixa Postal 17.315 – 80.242-980 – Curitiba – PR – Brasil

{enzo.campa, jasmini.rebecca, leandro.ceron}@pucpr.edu.br

Abstract—With the increase in the elderly population, maintaining quality of life has become a priority for healthcare professionals. Early detection of fatigue was identified as a crucial initiative, as it could prevent the onset of various common illnesses in this age group. This paper presents a new dataset that captured the body coordinates of twenty elderly individuals while performing exercises until the onset of fatigue. An exploratory analysis was conducted using this dataset to identify the bodily signals associated with fatigue. In addition, Machine Learning techniques applied to Time Series were used to predict the occurrence of fatigue, contributing to more effective interventions in elderly healthcare.

Resumo—Com o aumento da população idosa, a manutenção da qualidade de vida tornou-se uma prioridade para os profissionais de saúde. A detecção precoce da fadiga foi identificada como uma iniciativa fundamental, pois poderia prevenir o surgimento de diversas enfermidades comuns nessa faixa etária. Este artigo apresenta uma nova base de dados que capturou as coordenadas corporais de vinte idosos durante a realização de exercícios até o surgimento da fadiga. A partir dessa base, foi conduzida uma análise exploratória para identificar os sinais corporais associados ao cansaço. Além disso, foram aplicadas técnicas de aprendizado de máquina em séries temporais para prever a ocorrência da fadiga, contribuindo para intervenções mais eficazes na saúde dos idosos.

I. INTRODUÇÃO

Atualmente, devido ao aumento na qualidade de vida, tem-se observado um crescimento significativo da população idosa. Esse fenômeno tem gerado grande preocupação no campo da saúde, pois, devido à idade avançada, os idosos se tornam mais suscetíveis a doenças e lesões, em razão da menor resistência física e imunológica. Essa vulnerabilidade aumenta as chances de problemas de saúde graves, como demência, paralisia, perda de movimento e, em casos extremos, a morte.

Diante dessa preocupação, muitos médicos têm se empenhado em descobrir formas de tratar essa população idosa, buscando garantir que possam continuar a viver suas vidas de maneira normal. Uma das questões de destaque nesse cenário é a fadiga. De acordo com Mota et al. [2005], os principais atributos relacionados à fadiga incluem cansaço, exaustão, desgaste, alteração da capacidade funcional e falta de recursos/energia. Essas características, por si só, já podem causar diversos problemas de saúde, independentemente da idade. Contudo, nos idosos, considerando sua maior fragilidade, a predisposição a essas enfermidades é significativamente maior.

Portanto, torna-se evidente a importância da área da saúde no monitoramento e prevenção da fadiga em idosos. Detectar a fadiga antes que ela resulte em uma queda é crucial, visto que, como demonstrado, essa situação pode acarretar sérias consequências para a vida do idoso.

Com base nisto, este trabalho tem como objetivo utilizar técnicas de aprendizado de máquina em séries temporais para auxiliar na detecção de fadiga em idosos. Para isso, será introduzido uma nova base de dados, coletada e disponibilizada pela parceria realizada com o Programa de Pós-Graduação em Tecnologia da Saúde (PPGTS) da Pontifícia Universidade Católica do Paraná (PUCPR), composta pelo Professor Eduardo Mendonça Scheeren e a doutoranda Rafaela Machado.

Para alcançarmos nossos objetivos descritos anteriormente, iremos utilizar o método de experimentação utilizando as seguintes hipóteses:

- **Hipótese Nula (H0):** Não é possível utilizar técnicas de aprendizado de máquina para detectar a ocorrência de fadiga em idosos.
- **Hipótese Alternativa (H1):** É possível utilizar técnicas de aprendizado de máquina para detectar a ocorrência de fadiga em idosos.

Para isso, iremos utilizar os algoritmos estado da arte na base descrita acima, onde iremos comparar as acurácias dos modelos e seus custos computacionais.

Este artigo está estruturado da seguinte forma: o Capítulo II apresenta a fundamentação teórica utilizada neste estudo, abordando os conceitos de fadiga, séries temporais e os classificadores de aprendizado de máquina empregados. O Capítulo III aborda o estado da arte utilizado como base dessa pesquisa, detalhando conceitos relacionados à fadiga, tecnologias de monitoramento e técnicas de detecção utilizadas para problemas relacionados. No Capítulo IV, são detalhadas as características da base de dados utilizada, incluindo o processo de coleta e as anotações essenciais realizadas para possibilitar os experimentos. O Capítulo V descreve a metodologia adotada na condução dos experimentos, enquanto o Capítulo VI apresenta os resultados obtidos com a aplicação da metodologia proposta. Por fim, o Capítulo VII conclui o trabalho com um resumo dos principais achados e sugestões para futuros estudos que possam aprofundar o tema explorado neste artigo.

Os agradecimentos estão formalizados no Capítulo VIII, em reconhecimento às contribuições que viabilizaram este estudo.

II. FUNDAMENTAÇÃO TEÓRICA

Este capítulo abrange uma análise dos conceitos de fadiga e as metodologias para sua detecção e monitoramento. Examinam-se as implicações da fadiga na saúde e na produtividade, com ênfase nos idosos, avaliando o papel das tecnologias vestíveis e técnicas de aprendizado de máquina na monitorização dessa condição. Discutem-se ainda os avanços nas abordagens analíticas, incluindo o uso de séries temporais e a eficiência de alguns classificadores de machine learning, para fornecer um entendimento abrangente sobre estratégias adequadas de intervenção na fadiga relacionada a exercícios.

A. Conceitos Básicos de Fadiga

A fadiga é uma condição caracterizada por um declínio acentuado tanto na capacidade física quanto mental, atribuída a fatores como esforço prolongado, desequilíbrio circadiano, e falta de sono. Segundo Adão Martins et al. [2021], essa condição não somente impacta negativamente a produtividade e eficiência nas atividades laborais, mas também eleva substancialmente o risco de acidentes em ambientes ocupacionais críticos como o setor de transporte. Além disso, a complexidade e a natureza multifacetada da fadiga, influenciada por uma vasta gama de variáveis interconectadas, dificultam a concepção de uma definição unificada e abrangente. Ainda assim, é fundamental reconhecer a fadiga não apenas como uma resposta fisiológica natural do corpo a excessos, mas também como um sintoma associado a diversas doenças e condições de saúde, o que ressalta a importância de sua detecção precoce e cuidado adequado.

Em idosos, a fadiga pode ter impactos significativos na qualidade de vida, uma vez que afeta tanto a capacidade de realizar atividades diárias quanto a função cognitiva, aumentando o risco de quedas, diminuição da independência e potencial deterioração da saúde mental [Varandas et al., 2022]. A detecção e monitoramento eficazes da fadiga em idosos são, portanto, essenciais para intervenções oportunas que possam mitigar esses efeitos e promover um envelhecimento saudável.

A aplicação de tecnologias vestíveis e algoritmos de machine learning emerge como uma abordagem promissora na monitorização contínua da fadiga em idosos, possibilitando a detecção precoce de sinais de fadiga física e mental através da análise de dados fisiológicos e de movimento em tempo real, similares ao processos ilustrados na figura 1 [Varandas et al., 2022, Hayat et al., 2022].




Fig. 1. Arquitetura convencional de aprendizado de máquina para reconhecimento de atividades humanas [Hayat et al., 2022].

B. Séries Temporais

Uma série temporal é uma sequência de pontos de dados coletados, registrados ou medidos em intervalos de tempo sucessivos. A capacidade de prever séries temporais é crucial em vários campos, como finanças, meteorologia e vendas, pois permite antecipar futuros valores com base em tendências passadas e presentes. Este aspecto é essencial para a tomada de decisões informadas em ambientes corporativos e governamentais (Murray et al., 2022).

O estudo realizado por Murray et al. [2022] oferece uma análise comparativa dos algoritmos de ponta para previsão de séries temporais, destacando a crescente demanda por capacidades de previsão em domínios desafiadores e problemas de análise de dados. As séries temporais, fundamentais para prever valores futuros com base em sequências passadas, têm evoluído significativamente desde as primeiras metodologias de Holt-Winters e Box-Jenkins, passando por modelos estatísticos como ARIMA, até as soluções recentes que incorporam aprendizado profundo.

A pesquisa avalia oito algoritmos de ponta, incluindo LSTM (Vanilla, Bidirecional, e com Autoencoder), GRU, CNN-LSTM, ConvLSTM, redes com mecanismo de Atenção e a rede Transformer, em cinco conjuntos de dados de benchmark abrangendo finanças, meteorologia e vendas. A pesquisa visa determinar se métodos de previsão diretos ou iterativos são ótimos para a previsão, empregando uma estrutura de validação cruzada de 10 k-folds com o algoritmo ASHA para otimização de modelo.

Os resultados revelam que, embora existam diferenças entre todos os modelos, as disparidades são insignificantes entre os modelos de melhor desempenho, que incluem o Transformer, Atenção, V-LSTM, CNN-LSTM e CV-LSTM. Notavelmente, o modelo Transformer consistentemente produziu o menor erro de previsão, evidenciando sua robustez e versatilidade em uma gama diversificada de aplicações de previsão de séries temporais.

C. Classificadores de Machine Learning

Nesta seção, são explorados alguns classificadores de machine learning, fundamentais para previsões e classificações em inteligência artificial. Serão abordadas as características, métodos de implementação e aplicações práticas de cada classificador. Este estudo proporciona uma visão abrangente sobre como esses algoritmos operam em variados contextos de dados.

1) Regressão Logística

A regressão logística é utilizada para identificar a relação entre variáveis dependentes e independentes, sendo a variável dependente a classe alvo a ser prevista. Esta técnica retorna a probabilidade de uma instância pertencer a uma determinada classe, baseada na função logística, que minimiza o erro e limita a saída entre 0 e 1. Devido à sua implementação simples e à falta de necessidade de ajuste crítico de hiperparâmetros, a regressão logística é amplamente utilizada em contextos clínicos [Prinzi et al., 2024]. Em particular, o artigo enfatiza que a função logística, ou função sigmoide, é usada como

a função de separação, adequando-se à curva dos pontos de dados para minimizar o erro e comprimir a saída de uma equação linear entre 0 e 1. Durante o processo de treinamento, é empregada uma função de perda conhecida como "estimativa de máxima verossimilhança" para estimar o erro entre as saídas previstas e reais. Se a saída estimada para uma instância for superior a 50%, o modelo prevê a classe positiva; caso contrário, prevê a classe negativa, definindo assim o caráter binário da classificação.

2) *Support Vector Machine (SVM)*

O algoritmo SVM é projetado para encontrar um hiperplano ótimo que separa efetivamente os dados em classes distintas. Este algoritmo é caracterizado pelo seu foco em vetores de suporte, pontos de dados específicos que são essenciais para definir a posição e orientação do hiperplano decisivo. A maximização da margem, a distância entre o hiperplano de separação e os vetores de suporte, é uma característica chave da SVM, refletida no conceito de "hard margin" [Prinzi et al., 2024].

Entretanto, em alguns casos, é necessário permitir certo erro de classificação para melhorar a capacidade de generalização do modelo, o que leva ao conceito de "soft margin". A gestão dessa flexibilidade é controlada pelo parâmetro de regularização C , que ajusta o trade-off entre maximizar a margem e minimizar o erro de treinamento. Um valor menor de C indica uma tolerância maior para com os erros de classificação durante o treinamento, favorecendo a generalização, enquanto um valor maior de C foca na precisão do modelo nos dados de treinamento, potencialmente às custas da generalização.

Nos casos em que os dados não são linearmente separáveis, o algoritmo SVM utiliza o truque do kernel para projetar os dados em uma dimensão mais alta, onde se tornam separáveis. Esta etapa é fundamental, pois a escolha do kernel adequado afeta diretamente a distribuição dos dados no novo espaço e, por consequência, o desempenho da classificação.

3) *Redes Neurais Convolucionais (CNN)*

Prinzi et al. (2024) explicam que as redes neurais convolucionais (CNNs) são essenciais na análise de imagens devido à sua capacidade de integrar a extração de características diretamente em seu processo de análise, tornando-as particularmente interessantes para aplicações em imagens médicas. A arquitetura de uma CNN é composta por camadas sequenciais que incluem camadas de convolução e de pooling. As camadas de convolução aplicam filtros ajustáveis que permitem à rede aprender a identificar características específicas, como texturas ou bordas, enquanto as camadas de pooling ajudam a reduzir a dimensionalidade dos dados, aumentando a eficiência do processo de aprendizado. Esse arranjo permite que as CNNs processem informações desde o nível mais básico até características complexas e abstratas, cruciais para a classificação eficaz de imagens.

4) *K-Nearest Neighbors*

A abordagem KNN é um dos métodos de classificação mais simples, nos quais o algoritmo encontra os k exemplos mais próximos no conjunto de treinamento para atribuir a classe aos

novos dados. O processo de treinamento envolve o cálculo das distâncias entre os pontos de dados, e quando novos dados são introduzidos, essas distâncias precisam ser recalculadas. O algoritmo requer a definição de três hiperparâmetros principais: a cardinalidade do vizinho, que define quantos vizinhos serão verificados para a atribuição de classe, a métrica para estimar a distância entre os pontos vizinhos e a função de peso para atribuir um peso de acordo com a distância. O núcleo desse classificador depende principalmente da escolha da métrica para calcular a distância entre os exemplos testados e os exemplos de treinamento [Prinzi et al., 2024].

5) *Random Forest*

Este algoritmo treina múltiplas árvores de decisão, cada uma considerando um subconjunto aleatório dos dados, e melhora a estabilidade e a precisão através de um mecanismo de votação das árvores. É útil em casos de dados ausentes e ruidosos, com a configuração do número de estimadores sendo um hiperparâmetro importante [Prinzi et al., 2024].

O estudo explora o uso desse algoritmo para treinar múltiplas árvores de decisão (DTs), utilizando uma técnica chamada bagging, que permite o treinamento de cada DT em uma porção aleatória do conjunto de dados. Esse método gera resultados variados para cada DT individual, pois elas são treinadas com dados e características diferentes. A agregação das previsões de todas as DTs através de um mecanismo de votação é o que confere ao RF sua robustez, melhorando a estabilidade e a acurácia do modelo. Um hiperparâmetro chave no RF é o número de estimadores, que é o número de DTs na floresta, e embora não haja uma regra geral para definir esse número, outro parâmetro importante é o número máximo de características usadas no treinamento de cada DT. O RF é considerado adequado para casos com dados ausentes ou com ruído.

D. *Catch22*

O catch22 (CANonical Time-series CHaracteristics) é um conjunto reduzido e eficiente de 22 características selecionadas a partir de milhares de potenciais características de séries temporais. Ele foi desenvolvido para capturar as propriedades dinâmicas das séries temporais e facilitar tarefas como classificação e agrupamento. O processo de seleção para o catch22 envolve a análise comparativa de um grande número de características em uma ampla variedade de conjuntos de dados, resultando em um conjunto final que é computacionalmente rápido, com escalabilidade quase linear e perda mínima de precisão (apenas cerca de 7%) quando comparado ao uso de um conjunto completo de 4791 características [Lubba et al., 2019].

O catch22 serve para reduzir a dimensionalidade dos dados de séries temporais de forma eficiente, mantendo uma alta taxa de acurácia, mas reduzindo o tempo de processamento em aproximadamente mil vezes. Isso resolve problemas de análise de séries temporais em aplicações que exigem velocidade e eficiência, como na indústria, finanças e medicina. Os resultados mostram que o catch22 oferece uma solução equilibrada entre desempenho e custo computacional, mantendo a

interpretabilidade dos resultados e facilitando sua integração em diversos ambientes de programação, como Python, R e Matlab [Lubba et al., 2019].

E. Desbalanceamento

O desbalanceamento de classes é uma ameaça significativa na mineração de dados, caracterizado por uma grande discrepância entre duas classes da variável alvo, onde uma classe é representada por muitas instâncias e a outra por um número muito menor. Esse problema é comum em contextos críticos, como a previsão de evasão escolar ou falhas acadêmicas. Como as classes minoritárias, como alunos que abandonam a escola ou têm notas baixas, são menos frequentes, um algoritmo de aprendizado pode falhar ao classificá-las adequadamente, favorecendo a classe majoritária devido ao maior tamanho amostral [Wongvorachan et al., 2023].

Para mitigar o problema de desbalanceamento de classes, pesquisadores desenvolveram técnicas de aprendizado focadas em processar e extrair informações de dados com distribuições altamente enviesadas. Essas técnicas permitem que algoritmos preditivos alcancem um nível de acurácia mais realista, ao invés de ignorar classes minoritárias, como alunos que abandonam a escola. A abordagem pode se concentrar em modificar o próprio algoritmo preditivo ou melhorar o conjunto de dados. No caso do ajuste de dados, os pesquisadores podem utilizar técnicas de oversampling para equilibrar a proporção entre as classes da variável alvo. Além disso, é possível criar algoritmos de classificação que levem em consideração o desbalanceamento de classes, como os classificadores baseados em ensembles. Essas técnicas são amplamente utilizadas na mineração de dados educacionais, onde o desbalanceamento pode afetar a previsão de resultados críticos, como evasão escolar e matrícula no ensino superior. A aplicação dessas técnicas em contextos educacionais demonstra como diferentes estratégias, como o oversampling, o undersampling e métodos híbridos, podem ser utilizadas para lidar com diferentes níveis de desbalanceamento [Wongvorachan et al., 2023].

III. ESTADO DA ARTE

Neste capítulo, será apresentado alguns estudos já realizados na detecção de fadiga, mostrando seus achados e suas contribuições para esse estudo.

1) Tecnologias de Monitoramento

A importância e o impacto das tecnologias vestíveis na detecção da fadiga cognitiva são destacados por Varandas et al. [2022]. Utilizando dispositivos fNIRS vestíveis junto com algoritmos de aprendizado de máquina, este estudo visa detectar automaticamente estados de fadiga cognitiva. As tecnologias vestíveis oferecem a vantagem de monitorar os pacientes de maneira não intrusiva, permitindo a coleta de dados em tempo real em ambientes naturais. Esse avanço abre caminho para monitoramentos cognitivos contínuos, facilitando intervenções personalizadas e mais efetivas.

No estudo, procedimentos experimentais foram conduzidos para induzir a fadiga cognitiva efetivamente, através de uma

aula digital e tarefas cognitivas padrão. Através dos dispositivos fNIRS, os dados fisiológicos dos participantes foram coletados e, posteriormente, analisados com algoritmos de machine learning, alcançando uma precisão de classificação de aproximadamente 70,91%. Esses resultados evidenciam o potencial da combinação dos dispositivos vestíveis fNIRS com o aprendizado de máquina para uma detecção precisa e individualizada da fadiga cognitiva.

A adaptabilidade dessas tecnologias às dinâmicas individuais dos usuários, sem a necessidade de equipamentos complexos ou ambientes especializados, marca um avanço significativo para sua aplicação em cenários reais, como o e-learning, entre outros contextos de aprendizado. Esta abordagem não só melhora a eficácia do monitoramento da fadiga cognitiva, mas também suporta o desenvolvimento de intervenções personalizadas, otimizando o processo de aprendizado e a produtividade, ao mesmo tempo em que minimiza o risco de sobrecarga cognitiva.

O estudo conduzido por Hayat et al. [2022] aborda o desafio do reconhecimento de atividades humanas em idosos, utilizando algoritmos de aprendizado de máquina e aprendizado profundo. Com o envelhecimento, a capacidade física e a autonomia para realizar tarefas diárias tendem a diminuir, afetando a saúde física e mental dos idosos. Diante disso, a pesquisa propõe um sistema de monitoramento assistido que emprega dados de acelerômetro e giroscópio coletados de smartphones para reconhecer atividades rotineiras, como se sentar, andar, subir escadas, entre outras.

O estudo destaca o papel crucial dos smartphones como dispositivos de monitoramento acessíveis e robustos, que, aliados a algoritmos como K-Nearest Neighbors, Random Forest, Support Vector Machine, Artificial Neural Network, e Long Short-Term Memory (LSTM), alcançam uma precisão notável na identificação de atividades. Especificamente, o modelo LSTM apresentou a melhor precisão, atingindo 95,04% de acurácia. Este desempenho exemplifica o potencial do uso de tecnologias vestíveis e de aprendizado de máquina para aprimorar o cuidado e o suporte aos idosos, promovendo uma maior independência e segurança.

2) Abordagens Para Detecção de Fadiga

Hooda et al. [2022] oferecem uma revisão abrangente sobre métodos de detecção de fadiga utilizando técnicas de aprendizado de máquina, destacando a crescente prevalência da fadiga em um mundo em rápida transformação e a necessidade de abordagens eficazes para sua detecção. São discutidos também efeitos que podem ser utilizados para detecção, como detalhado na figura 2. Eles introduzem e discutem métodos e avanços recentes na detecção de fadiga, categorizando as abordagens em modelos matemáticos, implementações baseadas em regras, aprendizado de máquina e aprendizado profundo, as quais são exemplificadas na figura 3.. A revisão compara e contrasta vários algoritmos para identificar a abordagem mais promissora para a detecção de fadiga, destacando áreas para melhorias futuras.

Dentre as abordagens de detecção de fadiga, os métodos de aprendizado de máquina e aprendizado profundo apresentam

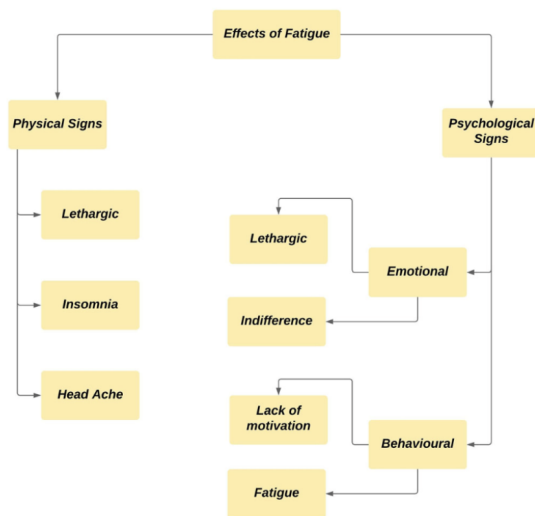


Fig. 2. Classificação dos efeitos da fadiga com base nas manifestações clínicas [Hooda et al., 2022].

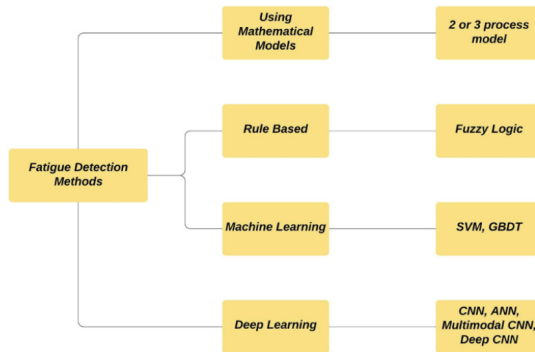


Fig. 3. Métodos para classificação de fadiga [Hooda et al., 2022].

se como promissores, abrangendo o monitoramento de sinais eletroencefalográficos (EEG), detecção de bocejos, análise de músculos faciais, detecção de sonolência e identificação de pupilas, com o EEG sendo particularmente notável pela sua eficácia na detecção de padrões de sono e, por consequência, na detecção de fadiga.

Por fim, a revisão conclui que aprendizado de máquina e aprendizado profundo podem ser úteis tanto na detecção quanto no diagnóstico da fadiga, potencializando o avanço do setor de saúde. O artigo apresenta uma revisão detalhada das descobertas de pesquisa relacionadas à detecção de fadiga, destacando o caminho para futuras inovações na área.

O estudo de Gao et al. [2023] investigou o impacto da fadiga induzida por corrida na distribuição da força plantar nos pés dominante e não dominante de corredores amadores. Utilizando medidas pedobarográficas, o estudo objetivou facilitar o reconhecimento automático da marcha fatigada por meio de modelos de rede neural convolucional (CNN) e rede neural de longo-curto prazo baseada em CNN (ConvLSTM). A coleta de dados da força plantar foi realizada antes e após um protocolo

de indução de fadiga em corrida, usando uma placa de força FootScan, e os dados foram analisados com os modelos de aprendizado profundo implementados na biblioteca Keras do Python.

Os resultados demonstraram que, após a fadiga, ocorreu um aumento significativo da força na região do meio do pé anterior e do calcanhar durante a plantar bilateral, com uma diminuição da força na região média do pé no membro dominante. O modelo ConvLSTM mostrou desempenho superior (acurácia= 0.867, sensibilidade= 0.874 e especificidade= 0.859) na detecção da marcha fatigada em comparação com o modelo CNN (acurácia= 0.800, sensibilidade= 0.874 e especificidade= 0.718). Esses achados podem oferecer dados empíricos para avaliar fatores de risco associados a lesões por uso excessivo em um único membro, além de facilitar a detecção precoce da marcha fatigada.

A abordagem deste estudo, utilizando pedobarografia e modelos de aprendizado profundo, indica um caminho promissor para o monitoramento e a intervenção precoce na fadiga induzida por corrida, contribuindo para a prevenção de lesões e a otimização do treinamento de corredores amadores.

3) Séries Temporais na detecção de fadiga

O estudo de Hajifar et al. [2020] destaca a aplicação de métodos de séries temporais para prever a fadiga física, um passo essencial na ergonomia e na segurança do trabalho. As séries temporais, que analisam dados ao longo do tempo para identificar padrões e prever eventos futuros, são particularmente úteis na detecção da fadiga, permitindo intervenções preventivas antes que a fadiga afete negativamente o desempenho e a segurança.

O estudo compara cinco modelos de previsão de séries temporais — métodos ingênuos, autorregressivos (AR), autorregressivos integrados de médias móveis (ARIMA), autorregressão vetorial (VAR) e modelo de correção de erro vetorial (VECM) — usando dados de percepção subjetiva de esforço (RPE) e dados de marcha de sensores vestíveis. O modelo VECM, que integra dados históricos de RPE e de sensores vestíveis, superou os demais modelos, fornecendo previsões precisas para até três períodos à frente, com um erro médio absoluto (MAE) inferior a 1,24 em todos os participantes.

A capacidade dos dados de sensores vestíveis de melhorar significativamente a precisão das previsões de fadiga destaca a importância dessas tecnologias na previsão da condição do trabalhador. O sucesso do modelo VECM em fornecer previsões precisas demonstra o potencial das séries temporais e dos sensores vestíveis em monitorar e intervir na fadiga antes que ela comprometa a segurança e o desempenho.

O estudo conduzido por Biró et al. [2024] explora o uso de Unidades de Medição Inercial (IMUs) e inteligência artificial para monitorar e otimizar ciclos de treinamento de atletas, visando equilibrar desempenho esportivo de alta performance com o controle adequado de fadiga e resistência. Este estudo destaca-se por sua abordagem inovadora na coleta e análise de dados multivariados de séries temporais, gerados por IMUs, para prever níveis de fadiga e ajustar as rotinas de treinamento de forma individualizada.

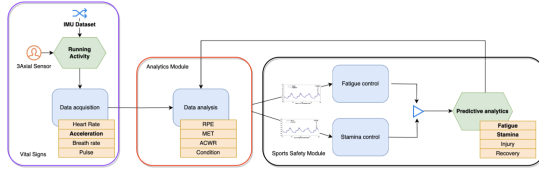


Fig. 4. Arquitetura do sistema de monitoramento de atividades de corrida [Biró et al., 2024].

Utilizando IMUs acopladas a 19 atletas, os pesquisadores registraram aceleração triaxial, velocidade angular e orientação magnética ao longo de sessões repetidas, que incluíam corridas de ritmo constante e técnicas indutoras de fadiga, conforme a lógica presente na figura 4. Dados brutos das séries temporais foram empregados para treinar um modelo de aprendizado de máquina supervisionado, baseado em características de domínio de frequência e tempo. Foram comparados os desempenhos de modelos Random Forest, Gradient Boosting Machines e redes LSTM, com um loop de feedback ajustando o modelo em tempo real baseado em erro de previsão e estimativa de vies.

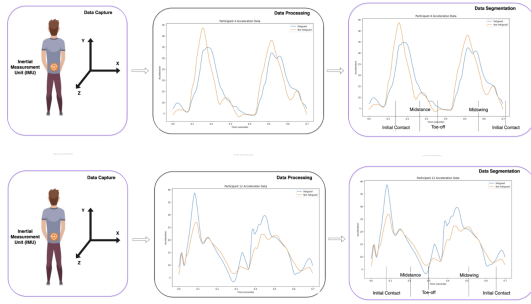


Fig. 5. Coleta, processamento e segmentação de dados pelo IMU em séries individuais [Biró et al., 2024].

O modelo demonstrou alta precisão preditiva para fadiga, exibindo correlações significativas entre os níveis de fadiga previstos e os declínios observados no desempenho. As previsões de resistência possibilitaram ajustes de treinamento individualizados, sincronizados com os limiares fisiológicos dos atletas, destacados na figura 5. Mecanismos de correção de vies se mostraram eficazes na minimização de erros de previsão sistemáticos. Adaptações em tempo real do modelo conduziram a estratégias de periodização de treinamento aprimoradas, reduzindo o risco de treinamento excessivo e melhorando o desempenho atlético geral.

O estudo conclui que o modelo assistido por IA utilizando dados multivariados de séries temporais gerados por IMU, é eficaz na análise de desempenho esportivo. O treinamento pode ser personalizado e constantemente alterado, pois o modelo prevê com precisão a fadiga e a energia. O modelo de IA pode prever efetivamente o início da fadiga antes que sintomas físicos se manifestem, permitindo intervenções oportunas para evitar treinamento excessivo e possíveis acidentes. Ele exibe uma boa capacidade de personalizar programas de

treinamento de acordo com as reações fisiológicas de cada atleta, melhorando a eficácia geral do treinamento. Além disso, o estudo demonstrou a eficácia do modelo em monitorar o desempenho em tempo real, aprimorando a capacidade de tomada de decisão de treinadores e atletas.

IV. BASE DE DADOS

Como anteriormente mencionado, para a realização desse trabalho foi construída uma nova base de dados com auxílio da parceria do programa PPGTS da PUCPR, neste capítulo será apresentado do que se trata esta base, como foi coletado e como feito a sua anotação.

A. Descrição da Base

A base de dados decorre de um experimento realizado pelo grupo do programa PPGTS, no qual foram selecionados 20 participantes idosos, sendo 11 do sexo feminino e 9 do masculino, que realizaram o exercício de levantar-se e sentar-se repetidamente até que se sentissem indispostos a continuar ou que a coleta fosse interrompida, demonstrada na Fig: 6. Esses exercícios foram realizados em ritmos definidos por sinais sonoros, dos quais, aumentavam progressivamente ao longo da coleta.




Fig. 6. Imagem representando exercício realizado pelos idosos, adaptado de: <https://blogeducacaofisica.com.br/exercicios-funcionais-para-idosos/>

A base de dados foi composta com o auxílio do programa OptiTrack, uma ferramenta desenvolvida para capturar o movimento realizado por pessoas com o suporte de câmeras e roupas especiais que destacam pontos específicos do corpo humano, apresentada na Fig: 7. Com essa coleta o programa consegue digitalizar o movimento realizado construindo um esqueleto virtual, que replica a movimentação capturada e demonstrado na Fig: 8.

Com essa coleta, foi possível extrair do programa OptiTrack a base de dados utilizada neste trabalho. A base contém as localizações tridimensionais (X, Y, Z) de 57 pontos do corpo do idosos ao longo do tempo durante o experimento descrito na Tab: I e apresentado suas posições no corpo humano na Fig: 9, configurando-se assim como uma série temporal exemplificada na Fig: 10.

TABLE I. Pontos do corpo que foram mapeados na base coletada.




Fig. 7. Imagem de uma pessoa utilizando a roupa essencial para coleta utilizando OptiTrack, adaptado de: https://v21.wiki.optitrack.com/index.php?title=Getting_Started



Fig. 8. Imagem mostrando representação virtual do corpo humano coletado no programa OptiTrack.

Sigla	Nome
LAH	Left Anterior Head
RAH	Right Anterior Head
LPH	Left Posterior head
RPH	Right Posterior head
SJN	Sternum Jugular Notch
SXS	Sternum Xiphoid Process
CV7	Cervical Spine Vertebra 7
TV2	Thoracic Spine Vertebra 2
TV7	Thoracic Spine Vertebra 7
LHGT	Left Glenohumeral Joint
RHGT	Right Glenohumeral Joint
LIAS	Left Iliac Anterior Spine
RIAS	Right Iliac Anterior
LIPS	Left Iliac Posterior Spine
RIPS	Right Iliac Posterior Spine
LCAJ	Left Clavicle-Acromion Joint
RCAJ	Right Clavicle-Acromion Joint
LHLE	Left Humerus Lateral Epicondyl
RHLE	Right Humerus Lateral Epicondyle
LHME	Left Humerus Medial Epicondyle
RHME	Right Humerus Medial Epicondyle
LUA	Left Upper Arm
RUA	Right Upper Arm
LHM2	Left Hand Second metacarpal
RHM2	Right Hand Second metacarpal
LUSP	Left Ulna Styloid Process
RUSP	Right Ulna Styloid Process
LRSP	Left Radius Styloid Process
RRSP	Right Radius Styloid Process
LFTC	Left Femoral greater Trochanter
RFTC	Right Femoral greater Trochanter
LFLE	Left Femur Lateral Epicondyle
RFLE	Right Femur Lateral Epicondyle
LFME	Left Femur Medial Epicondyle
RFME	Right Femur Medial Epicondyle
LTH	Left Thigh
RTH	Right Thigh
LSK	Left Superior Knee
RSK	Right Superior Knee
LTTC	Left Tibial Tubercle
RTTC	Right Tibial Tubercle
LFAX	Left Fibula Apex
RFAX	Right Fibula Apex
LFAL	Left Fibula Ankle Lateral
RFAL	Right Fibula Ankle Lateral
LTAM	Left Talus Ankle Medial
RTAM	Right Talus Ankle Medial
LFM5	Left Foot Fifth Metatarsal
RFM5	Right Foot Fifth Metatarsal
LFM2	Left Foot Second Metatarsal
RFM2	Right Foot Second Metatarsal

Sigla	Nome
LFM1	Left Foot First Metatarsal
RFM1	Right Foot First Metatarsal
LFCC	Left Foot Calcaneus
RFCC	Right Foot Calcaneus
LDPI	Left First Distal Phalanx
RDPI	Right First Distal Phalanx




Fig. 9. Imagem mostrando a localização ex-ata dos pontos no corpo humano, adaptado de https://v21.wiki.optitrack.com/index.php?title=Biomechanics_Markersets




Fig. 10. Gráfico demonstrando o movimento do ponto LFTC da base ao decorrer do tempo da coleta.

B. Anotação

A base anteriormente coletada pela equipe da PPGTS, possui o movimento realizado pelos 20 idosos, para a realização da anotação dessa base de dados, foi escolhido um dos pontos que mais representa a fadiga da pessoa em um movimento, o *Left Femoral greater Trochanter* (LFTC) do qual representa o ponto esquerdo do quadril, por ser o ponto do corpo onde é fácil de visualizar a movimentação ao decorrer do exercício e o ponto que apresenta maiores alterações quando o indivíduo, realizando o exercício, começa a fadigar. Na série temporal desse ponto foram destacados dois importantes pontos do movimento, o vale e o pico, onde respectivamente representam o momento em que o idoso está sentado na cadeira, e o momento que se completou o movimento de levantar-se.




Fig. 11. Imagem mostrando os pontos vale e picos localizados na série temporal.

Para a detecção dos pontos de vale e pico, foi montado um programa representado pelo Algorithm 1

Algorithm 1 Detecção de Vales e Picos

Input: Serie temporal representando o Eixo Y do ponto LFTC
Series

```

1: set max = maxSeries
2: set min = minSeries
3: set globalMean = (max + min)/2
4: set previouspoints = []
5: set uphill = False
6: set vales = []
7: set picos = []
8: for frame ∈ range size Series do
9:   set value = Series[frame]
10:  pp.append(value)
11:  if size pp > 25 then
12:    pp.pop(0)
13:  end if
14:  if size pp < 25 then
15:    continue
16:  end if
17:  set mean = avgSeries
18:  if mean < value and not uphill and value < globalMean then
19:    set : uphill = True
20:    vales.append(index)
21:  end if
22:  if mean > value and uphill and value > globalMean then
23:    set : uphill = False
24:    picos.append(index)
25:  end if
26: end for

```

Com os pontos extraídos, o time do PPGTS visualizou todas as séries temporais e realizou a anotação identificando se o movimento após cada vale ou pico representava um movimento normal, ou um movimento anormal causado pela fadiga, esses movimentos anormais foram classificados de diversos modos:

- **Platô:** O movimento apresenta um tempo maior da pessoa sentado ou em pé do que o esperado

- **Duplo:** O movimento apresenta dois picos antes do próximo vale
- **Ritmo:** O movimento apresenta um erro no ritmo que o exercício deveria permanecer
- **Pré-Pico:** O movimento apresenta um pico antes do verdadeiro pico
- **Erro na Coleta:** O movimento apresenta muitas falhas na coleta, seja perda de dados, ou alterações no movimento surreais.

V. MÉTODO PROPOSTO

Neste capítulo é apresentada a metodologia utilizada para a realização dos experimentos, com o intuito de alcançar o objetivo desse trabalho de detectar fadiga em idosos utilizando técnicas de aprendizado de máquina em series temporais.

Primeiramente, foi realizado uma análise exploratória da base, a fim de entender o comportamento dos dados e também para a remoção de casos que não representam os dados reais, seja por coleta incorreta ou por muitos dados faltantes.

Após essa análise foi definido o pipeline que foi utilizado para realizar os experimentos, descrita a seguir:

- 1) Segregação da series temporais em subidas e descidas, utilizando os pontos de vale e pico encontrados
- 2) Remoção de segmentos que não representam o problema corretamente de acordo com a análise exploratória.
- 3) PipeLine para Treino e Teste
 - Segregação da Base em Treino e Teste (12 Pessoas Treino, 5 Teste)
 - Montagem de Bases para Validação Cruzada, utilizando GroupShuffleSplit (10 Bases) Tab II.
- 4) Balanceamento das Classes utilizando RandomUnderSampler
- 5) Interpolação simples dos segmentos para remoção de dados faltantes
- 6) Extração de Features utilizando Catch22
- 7) Treino e Teste utilizando KNN ($k = 5$, $distance = dtw_distance$)
- 8) Avaliação da Acurácia e F1-SCORE

A remoção dos movimentos especificados no pipeline se deu por causa das situações encontradas na análise exploratória, onde demonstrou exemplos de séries com muitos dados faltantes e com mais de um movimento presente nelas, dos quais não representam corretamente o problema analisado.

Foi realizado o balanceamento das classes utilizando RandomUnderSampler, do qual, remove aleatoriamente exemplos da classe dominante, neste caso os movimentos normais, até as duas classes tivessem a mesma quantidade, assim evitando o algoritmo realizar overfitting em cima da classe predominante, sem aprender a outra classe presente.

A interpolação simples foi utilizada para corrigir os pequenos casos restantes de movimentos com dados faltantes e por conseguir corrigir esses pequenos erros sem alterações grandes no comportamento esperado do indivíduo.

Por fim foi utilizado um extrator de features: o Catch22. Esse extrator de features realiza a extração das 22 features

TABLE II
SEPARAÇÃO ENTRE TREINO E TESTE POR PESSOAS

Fold	Treino	Teste
0	0 1 2 4 8 10 11 12 13 14 15 17	3 5 6 7 16
1	1 4 6 8 9 10 11 12 13 14 15 17	0 2 3 5 7
2	0 1 2 4 5 6 7 9 12 15 16 17	3 8 10 11 14
3	0 1 2 4 6 7 8 10 12 14 15 16	3 5 11 13 17
4	0 2 3 4 5 6 8 10 11 12 13 15	1 9 14 16 17
5	1 2 5 7 8 9 10 11 12 13 14 15	0 3 4 6 16
6	0 1 2 3 5 6 8 9 10 13 14 15	4 7 11 12 17
7	0 2 3 4 5 6 9 10 12 13 15 16	1 7 8 11 14
8	0 1 3 5 6 8 10 11 12 14 16 17	2 4 7 9 15
9	3 4 5 7 8 10 11 12 14 15 16 17	0 1 2 6 13

mais importantes para representar uma série temporal, isso conseguiu simplificar o problema para a realização do experimento de forma mais rápida sem a perda significativa de representatividade das séries.

Para avaliar o resultado do algoritmo, foi utilizado a acurácia e o F1-Score 1, foi utilizado acurácia para visualizar o resultado geral do algoritmo e F1-Score foi utilizado para visualizar o resultado em relação aos casos anormais.

$$\begin{aligned}
 \text{Acurácia} &= \frac{TP + TN}{TP + TN + FP + FN} \\
 \text{Precision} &= \frac{TP}{TP + FP} \\
 \text{Recall} &= \frac{TP}{TP + FN} \\
 \text{F1-score} &= 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}
 \end{aligned} \tag{1}$$

VI. EXPERIMENTO

A. Análise Exploratória

A base de dados contém 20 pessoas, em média estas pessoas realizaram os exercícios em 94915 frames antes de ocorrer a fadiga, sendo o menor 19047 frames e o maior 215860 frames. Onde nesses frames, realizaram em média 474 movimentos de levantar e sentar, sendo no mínimo 70 e no máximo 1300. Estes movimentos foram realizados em média de 218 frames, sendo no mínimo de 57 frames e no máximo de 7004 frames. Esses dados encontram se organizados na tabela III.

Em média foram identificados 67 movimentos anormais em cada pessoa, sendo no mínimo 2 movimentos e no máximo 301 movimentos.

A base de dados possui um desbalanceamento na classe anotada, onde Fig 12 mostra que 85.9% de todos os movimentos são Normais, enquanto os outros 14.1% são os casos anormais.

TABLE III
ANÁLISE EXPLORATÓRIA DA BASE DE DADOS PARA DETECÇÃO DE FADIGA EM IDOSOS

Métrica	Média	Mínimo	Máximo
Frames até ocorrência de fadiga	94915	19047	215860
Movimentos de levantar e sentar	474	70	1300
Duração dos movimentos (em frames)	218	57	7004
Movimentos anormais identificados	67	2	301

Distribuição dos Dados de Classificação




Fig. 12. Imagem mostrando a distribuição da classe na base de dados.

Como anteriormente mencionado, foi utilizado o Eixo Y do ponto LFTC para realizar as anotações, com isso em mente, a seguir será apresentado uma análise mais a fundo desse ponto.

O eixo Y do ponto LFTC apresenta 1.78% do total como pontos nulos, esses pontos nulos estão distribuídos desigualmente nos movimentos, onde movimentos que possuíam menos de 85% de pontos não nulos perde grande parte do movimento impossibilitando sua visualização, Fig 13.

Também temos alguns casos onde o movimento foi representados com mais frames que o normal, esses casos representados pelas Fig 14 e Fig 15, são os casos já anotados como Platô, dos quais iram ser representados por mais frames que o normal, mas também temos alguns casos onde apresentam mais de um pico/vale da pessoa.

B. Resultados do experimento

Utilizando o pipeline definido anteriormente, o algoritmo de KNN apresentou as seguintes acurácias e f1-scores nas rodadas do experimento Tab IV, onde o algoritmo apresentou uma média de acurácia de 62.0% e uma média de F1-Score de




Fig. 13. Imagem mostrando um exemplo onde a série temporal apresenta menos que 85% de pontos não nulos.

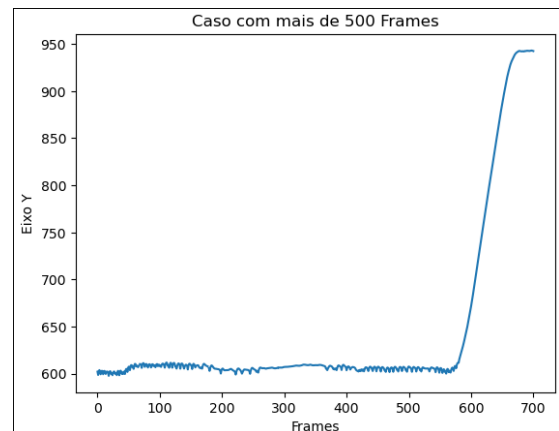


Fig. 14. Imagem mostrando um exemplo de um movimento classificado como platô com mais de 500 frames.




Fig. 15. Imagem mostrando um exemplo de um movimento com mais de 500 frames e mais de um pico ou vale.

TABLE IV
RESULTADOS ENCONTRADOS NA RODADA DE EXPERIMENTO DO
ALGORITMO KNN

Fold	Acurácias	F1-score
1	57.3%	65.2%
2	57.3%	64.5%
3	66.3%	72.0%
4	53.2%	62.5%
5	48.4%	56.3%
6	67.3%	71.1%
7	73.6%	80.9%
8	65.3%	69.7%
9	70.8%	72.6%
10	58.9%	65.5%
Média	62.0%	68.0%
Desvio Padrão	8.0%	6.0%

Valores em **Negrito** indica os melhores resultados para a métrica

68.0% e é observado que quando um fold apresenta resultados melhores de acurácia, influenciou positivamente o F1-Score Fig 16.




Fig. 16. Imagem mostrando a relação entre a acurácia do modelo e o f1-score.

Para poder visualizar melhor os resultados apresentados pelo algoritmo, foi escolhido a base de treino e teste que teve melhor F1-Score e observou em mais detalhes os Verdadeiros Positivos, Verdadeiro Negativos, Falso Positivos e Falso Negativos Fig 17, nele é possível observar que, ainda com ajuda do Undersampler para balanceamento dos dados, muitos casos anormais são classificados como casos normais, demonstrando uma possível falta de diferenciação grande entre essas duas classes, ou limitações do modelo KNN.

Por fim, para chegar em um resultado mais conclusivo na análise dos resultados, foi escolhido aleatoriamente uma das pessoas pertencentes a base de testes do fold que obteve o melhor resultado e extrair os segmentos e suas classificações (Verdadeiro Positivos, Verdadeiro Negativos, Falso Positivos, Falso Negativos). Começando pelos Verdadeiros Negativos, ao visualizar alguns exemplos Fig 18 estes demonstram ser casos classificados como normais que são facilmente identificados como normais, sem alterações e mudanças bruscas no movimento, mas existe exemplos Fig 19 onde apresentam




Fig. 17. Imagem mostrando a tabela de confusão do algoritmo KNN utilizando o melhor Fold

mudanças bruscas de várias subidas e descidas, estes casos podem ser indicadores não anotados de fadiga, ou falha na coleta do movimento.




Fig. 18. Imagem mostrando um segmento que foi classificado como Verdadeiro Negativo




Fig. 19. Imagem mostrando um segmento que foi classificado como Verdadeiro Negativo, mas com alterações anormais

Observados os Verdadeiros Positivos, é observado exemplos simples de movimentos que indicam a Fadiga, como Platô Fig 20 e movimentos como Duplo Fig 21, dos quais são facilmente distinguidos de casos normais. Mas também apresentam exemplos Fig 22 bem parecidos com exemplos de Verdadeiros Negativos, o que pode identificar novamente uma falha na coleta do movimento e também uma possível inconsistência nas anotações realizadas.

Passando para os Falsos Positivos, pode-se identificar exatamente os mesmos movimentos já identificados anteriormente nos Verdadeiros Positivos e Verdadeiros Negativos Fig 23, onde apresentam essas alterações rápidas ocorridas no começo




Fig. 20. Imagem mostrando um segmento anotado como Platô e classificado como Verdadeiro Positivo




Fig. 21. Imagem mostrando um segmento anotado como Duplo e classificado como Verdadeiro Positivo

ou fim do movimento. O que demonstra que essa alteração foi utilizada como um parâmetro para classificar como anormal.

Finalmente, ao observar os Falsos Negativos Fig 24 novamente observamos a anomalia já descrita nos outros casos, ou seja, é possível que essas anomalias tiveram entendimentos diferentes ao longo da anotação

Esses entendimentos diferentes para um mesmo tipo de alteração nas anotações, pode ser explicado ao observar a seguinte Fig 25, está imagem apresenta a quantidade de segmentos de cada pessoa e quantas delas foram classificadas como Normais ou Anormais, nele é possível observar que a



Fig. 22. Imagem mostrando um segmento classificado como Verdadeiro Positivo, mas com alterações anormais




Fig. 23. Imagem mostrando um segmento classificado como Falso Positivo, mas com alterações anormais




Fig. 24. Imagem mostrando um segmento classificado como Falso Negativo, mas com alterações anormais

proporção de normais e anormais para cada pessoa não foi a mesma. Observando a pessoa 8, ela é única que tem mais casos de movimentos anormais do que casos de movimentos normais, e ao analisar o movimento dessa pessoa Fig 26 é visualizado exatamente os mesmos exemplos anteriores, onde neste caso foi classificado como Ritmo, do qual este entendimento não era repetido para todas as outras pessoas.




Fig. 25. Imagem apresentando a distribuição de segmentos entre as pessoas e a proporção de normais e anormais




Fig. 26. Imagem apresentando um segmento de uma das pessoas, com alterações anormais e classificado como Ritmo

Por fim é possível concluir que, o algoritmo de aprendizado de máquina utilizado junto com o pipeline definido, consegue identificar corretamente vários casos de indicadores de fadiga no movimento de uma pessoa, mas há casos que na base teve dois entendimentos diferentes para um mesmo tipo de movimento, onde nesses casos o algoritmo não consegue distinguir facilmente dentre um movimento normal de um anormal.

VII. CONCLUSÃO

A ocorrência de fadiga pode causar inúmeros problemas de saúde para a população idosa, sendo a detecção dela antes da sua presença de grande importância para médicos e doutores que desejam melhorar a qualidade de vida dessas pessoas. Aumentando suas expectativas de vida e melhorando seus dias a dia.

A representação de movimentos de idosos utilizando séries temporais se provou eficaz para representar a possível ocorrência de fadiga em idosos e com ajuda dos algoritmos de aprendizado de máquina conseguimos identificar alguns desses casos, mas para esses algoritmos consigam classificar corretamente mais casos de fadiga, este necessitam de uma anotação mais robusta do problema, evitando classificar diferentemente casos muito parecidos.

Por fim, para trabalhos futuros que queiram continuar procurando formas de classificar fadiga em idosos utilizando algoritmos de aprendizado de máquina em séries temporais, segue alguns pontos a serem levados em consideração:

- Realizar novas coletas com novas pessoas, realizando a anotação dos pontos de picos e vales e da classificação do movimento, juntamente da coleta com vários especialistas, afim de diminuir trabalhos futuros com separação de segmentos sub ótimos e evitar entendimentos duplos na classificação dos movimentos;
- Realizar experimentos com mais pontos do corpo, identificando se esses pontos trazem ganho de informação para o identificação da fadiga;
- Realizar experimentos com algoritmos de aprendizado de máquina que trabalham com detecção de anomalia.

VIII. AGRADECIMENTOS

Agradecimentos ao Programa de Pós-Graduação em Tecnologia da Saúde (PPGTS) da Pontifícia Universidade Católica do Paraná (PUCPR) pela parceria essencial na realização deste trabalho, com especial reconhecimento ao Professor Eduardo Mendonça Scheeren e à doutoranda Rafaela Machado, cuja colaboração foi fundamental para o desenvolvimento e disponibilização da base de dados utilizada no estudo.

REFERENCES

- D. D. C. F. Mota, D. A. L. M. Cruz, and C. A. M. Pimenta. Fadiga: uma análise do conceito. *Acta Paulista de Enfermagem*, 18:285–293, 2005. doi: 10.1590/S0103-21002005000300009.
- N. R. Adão Martins, S. Annaheim, C. M. Spengler, and R. M. Rossi. Fatigue monitoring through wearables: A state-of-the-art review. *Frontiers in Physiology*, 12:artigo 790292, 2021. doi: 10.3389/fphys.2021.790292.
- R. Varandas, R. Lima, S. Bermúdez I Badia, H. Silva, and H. Gamboa. Automatic cognitive fatigue detection using wearable fnirs and machine learning. *Sensors*, 22(11):4010, 2022. doi: 10.3390/s22114010.
- A. Hayat, F. Morgado-Dias, B. P. Bhuyan, and R. Tomar. Human activity recognition for elderly people using machine and deep learning approaches. *Information*, 13:275, 2022. doi: 10.3390/info13060275.
- C. Murray, P. Chaurasia, L. Hollywood, and D. Coyle. A comparative analysis of state-of-the-art time series forecasting algorithms. *IEEE Xplore*, 2022. doi: 10.1109/CSCI58124.2022.00021.
- F. Prinzi, T. Currier, S. Gaglio, and S. Vitabile. Shallow and deep learning classifiers in medical image analysis. *European Radiology Experimental*, 8:26, 2024. doi: 10.1186/s41747-024-00428-2.
- C. H. Lubba, S. S. Sethi, P. Knaute, S. R. Schultz, B. D. Fulcher, and N. S. Jones. catch22: Canonical time-series characteristics. *Data Mining and Knowledge Discovery*, 33:1821–1852, 2019. doi: 10.1007/s10618-019-00647-x.
- T. Wongvorachan, S. He, and O. Bulut. A comparison of undersampling, oversampling, and smote methods for dealing with imbalanced classification in educational data mining. *Information*, 14(1):54, 2023. doi: 10.3390/info14010054.
- R. Hooda, V. Joshi, and M. Shah. A comprehensive review of approaches to detect fatigue using machine learning techniques. *Chronic Diseases and Translational Medicine*, 8:26–35, 2022. doi: 10.1016/j.cdtm.2021.07.002.
- Z. Gao, L. Xiang, G. Fekete, J. S. Baker, Z. Mao, and Y. Gu. A data-driven approach for fatigue detection during running using pedobarographic measurements. *Applied Bionics and Biomechanics*, 2023. doi: 10.1155/2023/7022513.
- S. Hajifar, H. Sun, F. M. Megahed, L. A. Jones-Farmer, E. Rashedi, and L. A. Cavuoto. A forecasting framework for predicting perceived fatigue: Using time series methods to forecast ratings of perceived exertion with features from wearable sensors. *Applied Ergonomics*, 2020. doi: 10.1016/j.apergo.2020.103262.
- A. Biró, A. I. Cuesta-Vargas, and L. Szilágyi. Ai-assisted fatigue and stamina control for performance sports on imu-generated multivariate time series datasets. *Sensors*, 24:132, 2024. doi: 10.3390/s24010132.