

Enzo Ramon Campa, Jasmini Rebecca Gomes dos Santos e  
Leandro Ceron Durau

DETECÇÃO DE FADIGA EM IDOSOS UTILIZANDO  
SÉRIES TEMPORAIS  
- PROPOSTA DE PESQUISA CIENTÍFICA -

Trabalho de Conclusão de Curso apresentado ao curso de Bacharelado em Ciência da Computação da Pontifícia Universidade Católica do Paraná como requisito parcial para obtenção do título de Cientista da Computação.

Área de concentração: Ciência da Computação

Orientador: Professor André Gustavo Hochuli

Curitiba  
2024

Enzo Ramon Campa, Jasmini Rebecca Gomes dos Santos e  
Leandro Ceron Durau

DETECÇÃO DE FADIGA EM IDOSOS UTILIZANDO  
SÉRIES TEMPORAIS  
- PROPOSTA DE PESQUISA CIENTÍFICA -

Trabalho de Conclusão de Curso apresentado ao curso de Bacharelado em Ciência da Computação da Pontifícia Universidade Católica do Paraná como requisito parcial para obtenção do título de Cientista da Computação.

Área de concentração: Ciência da Computação

Orientador: Professor André Gustavo Hochuli

Curitiba  
2024

## RESUMO

Com o aumento do número de idosos na população, os profissionais de saúde têm focado seus esforços em como manter a qualidade de vida dessa população. Um desses esforços é na detecção de fadiga, da qual pode ser utilizada para evitar a possível ocorrência de várias enfermidades nessas pessoas. Para auxiliar nesse estudo, este trabalho apresentará uma nova base de dados contendo as coordenadas de vários pontos do corpo de vinte idosos que realizavam um exercício até a ocorrência de fadiga. Com essa base, será realizado a análise exploratória da base para entender quais sinais o corpo humano demonstra ao estar cansado e será usado técnicas de Aprendizado de Máquina em Séries Temporais para prever o acontecimento da fadiga nos idosos

Palavras-chaves: Séries Temporais, Fadiga, Aprendizado de Máquina, Previsão, Idosos.

## **ABSTRACT**

With the increase of the number of elderly people in the population, the health professionals have been focusing their efforts on how to maintain the healthy quality of that population. One of those efforts is the detection of fatigue that it can be used to prevent the possible occurrence of various health problems in this people. To help in this study this work presents a new dataset with the coordinates of various points in the body of twenty elderly subjects doing an exercise until the occurrence of fatigue. With this dataset, it will be produced an exploratory analysis to understand what signals the body presents when they start getting tired, and it will be used machine learning techniques on time series to forecast the occurrence of fatigue on the elderly people.

Keywords: Time Series, Fatigue, Machine Learning, Forecast, Elderly People.

## SUMÁRIO

<b>RESUMO.....</b>	<b>III</b>
<b>ABSTRACT .....</b>	<b>IV</b>
<b>LISTA DE FIGURAS.....</b>	<b>VII</b>
<b>LISTA DE TABELAS .....</b>	<b>VIII</b>
<b>LISTA DE ABREVIATURAS E SIGLAS .....</b>	<b>IX</b>
<b>CAPÍTULO 1 - INTRODUÇÃO .....</b>	<b>1</b>
1.1 INTRODUÇÃO .....	1
1.2 OBJETIVOS .....	3
1.3 ESTRUTURA DO DOCUMENTO.....	4
<b>CAPÍTULO 2 - REVISÃO DA LITERATURA .....</b>	<b>5</b>
2.1 FUNDAMENTAÇÃO TEÓRICA .....	5
2.1.1 Conceitos básicos de fadiga .....	5
2.1.2 Séries Temporais.....	6
2.1.3 Classificadores de Machine Learning.....	7
2.2 TRABALHOS ANTERIORES .....	10
2.2.1 Tecnologias de Monitoramento .....	10
2.2.2 Abordagens para detecção de fadiga.....	11
2.2.3 Séries Temporais na detecção de fadiga .....	12
<b>CAPÍTULO 3 - MÉTODO DE PESQUISA.....</b>	<b>15</b>
3.1 CARACTERIZAÇÃO DA PESQUISA .....	15
3.2 MÉTODO DE PESQUISA.....	15
<b>CAPÍTULO 4 - INFORMAÇÕES DA PESQUISA .....</b>	<b>16</b>
4.1 CRONOGRAMA.....	16
4.2 RISCOS .....	17
<b>REFERÊNCIAS BIBLIOGRÁFICAS .....</b>	<b>20</b>
<b>GLOSSÁRIO .....</b>	<b>21</b>
<b>APÊNDICE A – TÍTULO DO APÊNDICE A.....</b>	<b>22</b>



## LISTA DE FIGURAS

- Figura 1-1. Imagem representando exercício realizado pelos idosos, adaptado de  
<https://blogeducacaofisica.com.br/exercicios-funcionais-para-idosos/>..... 2
- Figura 1-2. Gráfico demonstrando um dos pontos da base ao decorrer do tempo da coleta.. 3

## LISTA DE TABELAS

Tabela 4-1. Planejamento após apresentação da Proposta. Fonte: os Autores	16
Tabela 4-2. Riscos do projeto. Fonte: os Autores.	17



## LISTA DE ABREVIATURAS E SIGLAS

SIGLA	SIGNIFICADO
PPGTS	Programa de Pós-Graduação em Tecnologia da Saúde
PUCPR	Pontifícia Universidade Católica do Paraná
LSTM	Long Short-Term Memory
EEG	Monitoramento de sinais Eletroencefalográficos
CNN	Rede Neural Convolucional
AR	Autorregressivo
ARIMA	Autorregressivo Integrados de Médias Móveis
VAR	Autorregressivo Vetorial
VECM	Modelo de Correção de Erro Vetorial
RPE	Percepção Subjetiva de Esforço
MAE	Erro Médio Absolute
IMUs	Unidades de Medição Inercial

# **CAPÍTULO 1 - INTRODUÇÃO**

## **1.1 Introdução**

Atualmente, por causa do aumento na qualidade de vida, tem-se observado um aumento significativo na população mais idosa. Ela tem sido uma grande preocupação do mundo da saúde, já que ela, pela sua idade mais avançada, tem mais suscetibilidade a doenças e a lesões, tendo em conta sua menor resistência física e imunológica, podendo ter altas chances de causar problemas de saúde severos como demência, paralisia, perda de movimento ou até a morte.

Com essa preocupação em mente, muitos médicos têm se esforçado para descobrir como tratar essa população mais idosa e permitir que consigam continuar a viver suas vidas normalmente. Uma dessas preocupações tem sido a fadiga.

Segundo Mota, Cruz e Pimenta (2005) <sup>1</sup>, os principais atributos relacionados a fadiga são cansaço, exaustão, desgaste, alteração da capacidade funcional e falta de recursos/energia. Essas características por si, já podem causar inúmeros problemas de saúde independentemente da idade, contudo os idosos, levando em consideração os pontos levantados acima, podem ser bem mais propícios a essas enfermidades.

Para exemplificarmos o ponto acima, imagine que uma pessoa jovem adulta saudável acabe sentido fadiga e acabe sofrendo uma queda. Pela sua maior resistência, ela somente sofrerá alguns arranhões em seu corpo e precisando de alguns minutos descansando para poder se recompor e conseguir continuar seu caminho.

Já quando comparado a um idoso saudável que acabe sentido fadiga e sofra uma queda. Pela sua maior idade, ao cair poderá causar uma fratura em seus ossos, da qual pode causar cortes em seus órgãos e uma hemorragia interna. Além disso pela sua possível falta de força possa não conseguir se levantar, necessitando de ajuda de outros.

Com esses pontos em mente, é possível visualizar a importância que a área da saúde possui na fadiga ocorrida em idosos, focando principalmente em como

pode-se detectá-la antes de ocorrer uma queda, da qual, como anteriormente demonstrada pode causar inúmeras enfermidades perigosas a vida do idoso.

Com isso em mente, pretende-se com esse trabalho detectar a ocorrência dessa fadiga em idosos utilizando técnicas de aprendizado de máquina.

Para isso, realizaremos uma parceria com o Programa de Pós-Graduação em Tecnologia da Saúde (PPGTS) da Pontifícia Universidade Católica do Paraná (PUCPR), composta pelo professor Eduardo Mendonça Scheeren e a Mestranda Rafaela Machado, os quais são os elaboradores da base que será explicada abaixo.


Essa base foi composta com ajuda do programa OptiTrack, um programa feito para capturar a movimentação de pessoas, com auxílio de câmeras e roupa utilizada pelas pessoas para destacar pontos do corpo. Onde o aplicativo mapeia a posição de vários pontos do corpo humano para criar um esqueleto virtual que realiza a movimentação capturada.

Com o programa, foi selecionado 20 candidatos idosos, 11 do sexo feminino e 9 do sexo masculino, do qual realizaram o exercício de se levantar e se sentar repetidamente até o idoso se sentir indisposto a continuar o exercício ou a coleta fosse parada. Esses exercícios eram feitos em ritmos definidos por sinais sonoros que aumentavam seu ritmo ao decorrer da coleta.



**Figura 1-1. Imagem representando exercício realizado pelos idosos, adaptado de <https://blogeducacaofisica.com.br/exercicios-funcionais-para-idosos/>**

Com essa coleta, foi construída a base que será utilizada nesse trabalho, onde apresenta-se as localizações (X, Y, Z) de vários pontos do corpo ao decorrer da coleta, ou seja, a base é uma série temporal da movimentação do corpo do idoso.



**Figura 1-2. Gráfico demonstrando um dos pontos da base ao decorrer do tempo da coleta**

Com essa base, primeiramente, será realizado uma análise exploratória da base com intenção de encontrar padrões que ocorrem na movimentação dos idosos ao começarem a apresentar sintomas de fadiga. Para assim, ser observado quais pontos apresentam mudanças em seu comportamento, dos quais indiquem a ocorrência de fadiga ao longo do tempo.

Após isso será utilizado os algoritmos estados da arte de aprendizado de máquina para séries temporais, assim será possível observar a possibilidade da utilização dessas técnicas de aprendizado de máquina para detectar a fadiga.

## 1.2 Objetivos

De acordo com os pontos acima tem-se que objetivo geral desse trabalho é:

- Prever a ocorrência de fadiga utilizando técnicas de aprendizado de máquina para séries temporais.

Para isso teremos nossos objetivos específicos que são:

- Encontrar padrões que representam sintomas de fadiga em dados físicos.
- Avaliar o desempenho de diversos algoritmos, pontuando vantagens e desvantagens de sua utilização.

Com esses objetivos alcançados será possível responder à pergunta de pesquisa que envolve esse trabalho:

- É possível prever a ocorrência de fadiga utilizando técnicas de aprendizado de máquina em séries temporais?

### **1.3 Estrutura do documento**

O capítulo 1, anteriormente apresentado, visa informar o leitor sobre o problema que estamos analisando e como iremos resolvê-lo.

O capítulo 2 aprofunda o referencial teórico descrito no capítulo 1 e apresenta trabalhos já realizados na área.

O capítulo 3 apresenta o método de pesquisa utilizado para alcançar aos nossos objetivos

O capítulo 4 apresenta o planejamento que será seguido nos próximos meses e os riscos que esse projeto possui e suas possíveis ações de contenção e contingência.

## **CAPÍTULO 2 - REVISÃO DA LITERATURA**

Essa revisão de literatura abrange uma análise dos conceitos de fadiga e as metodologias para sua detecção e monitoramento. Examinam-se as implicações da fadiga na saúde e na produtividade, com ênfase nos idosos, avaliando o papel das tecnologias vestíveis e técnicas de aprendizado de máquina na monitorização dessa condição. Discutem-se ainda os avanços nas abordagens analíticas, incluindo o uso de séries temporais e a eficiência de alguns classificadores de machine learning, para fornecer um entendimento abrangente sobre estratégias adequadas de intervenção na fadiga relacionada a exercícios.

### **2.1 Fundamentação Teórica**

Neste capítulo será apresentado a teoria em mais detalhes dos tópicos apresentados na introdução, sendo esses:

- Fadiga;
- Séries Temporais
- Classificadores de Machine Learning

#### **2.1.1 Conceitos básicos de fadiga**

A fadiga é uma condição caracterizada por um declínio acentuado tanto na capacidade física quanto mental, atribuída a fatores como esforço prolongado, desequilíbrio circadiano, e falta de sono. Segundo Adão Martins et al. (2021), essa condição não somente impacta negativamente a produtividade e eficiência nas atividades laborais, mas também eleva substancialmente o risco de acidentes em ambientes ocupacionais críticos como o setor de transporte. Além disso, a complexidade e a natureza multifacetada da fadiga, influenciada por uma vasta gama de variáveis interconectadas, dificultam a concepção de uma definição unificada e abrangente. Ainda assim, é fundamental reconhecer a fadiga não apenas como uma resposta fisiológica natural do corpo a excessos, mas também como um

sintoma associado a diversas doenças e condições de saúde, o que ressalta a importância de sua detecção precoce e cuidado adequado.

Em idosos, a fadiga pode ter impactos significativos na qualidade de vida, uma vez que afeta tanto a capacidade de realizar atividades diárias quanto a função cognitiva, aumentando o risco de quedas, diminuição da independência e potencial deterioração da saúde mental (VARANDAS et al., 2022). A detecção e monitoramento eficazes da fadiga em idosos são, portanto, essenciais para intervenções oportunas que possam mitigar esses efeitos e promover um envelhecimento saudável.

A aplicação de tecnologias vestíveis e algoritmos de machine learning emerge como uma abordagem promissora na monitorização contínua da fadiga em idosos, possibilitando a detecção precoce de sinais de fadiga física e mental através da análise de dados fisiológicos e de movimento em tempo real (VARANDAS et al., 2022; HAYAT et al., 2022).

### **2.1.2 Séries Temporais**

Uma série temporal é uma sequência de pontos de dados coletados, registrados ou medidos em intervalos de tempo sucessivos. A capacidade de prever séries temporais é crucial em vários campos, como finanças, meteorologia e vendas, pois permite antecipar futuros valores com base em tendências passadas e presentes. Este aspecto é essencial para a tomada de decisões informadas em ambientes corporativos e governamentais (Murray et al., 2022).

O estudo realizado por Murray et al. oferece uma análise comparativa dos algoritmos de ponta para previsão de séries temporais, destacando a crescente demanda por capacidades de previsão em domínios desafiadores e problemas de análise de dados. As séries temporais, fundamentais para prever valores futuros com base em sequências passadas, têm evoluído significativamente desde as primeiras metodologias de Holt-Winters e Box-Jenkins, passando por modelos estatísticos como ARIMA, até as soluções recentes que incorporam aprendizado profundo.

A pesquisa avalia oito algoritmos de ponta, incluindo LSTM (*Vanilla*, Bidirecional, e com *Autoencoder*), GRU, CNN-LSTM, ConvLSTM, redes com mecanismo de Atenção e a rede *Transformer*, em cinco conjuntos de dados de

benchmark abrangendo finanças, meteorologia e vendas. A pesquisa visa determinar se métodos de previsão diretos ou iterativos são ótimos para a previsão, empregando uma estrutura de validação cruzada de 10 *k-folds* com o algoritmo ASHA para otimização de modelo.

Os resultados revelam que, embora existam diferenças entre todos os modelos, as disparidades são insignificantes entre os modelos de melhor desempenho, que incluem o *Transformer*, Atenção, V-LSTM, CNN-LSTM e CV-LSTM. Notavelmente, o modelo *Transformer* consistentemente produziu o menor erro de previsão, evidenciando sua robustez e versatilidade em uma gama diversificada de aplicações de previsão de séries temporais.

### 2.1.3 Classificadores de Machine Learning

Nesta seção, são explorados alguns classificadores de machine learning, fundamentais para previsões e classificações em inteligência artificial. Serão abordadas as características, métodos de implementação e aplicações práticas de cada classificador. Este estudo proporciona uma visão abrangente sobre como esses algoritmos operam em variados contextos de dados.

#### 2.1.3.1 Regressão Logística

A regressão logística é utilizada para identificar a relação entre variáveis dependentes e independentes, sendo a variável dependente a classe alvo a ser prevista. Esta técnica retorna a probabilidade de uma instância pertencer a uma determinada classe, baseada na função logística, que minimiza o erro e limita a saída entre 0 e 1. Devido à sua implementação simples e à falta de necessidade de ajuste crítico de hiperparâmetros, a regressão logística é amplamente utilizada em contextos clínicos (Prinzi et al., 2024).

Em particular, o artigo enfatiza que a função logística, ou função sigmoide, é usada como a função de separação, adequando-se à curva dos pontos de dados para minimizar o erro e comprimir a saída de uma equação linear entre 0 e 1. Durante o processo de treinamento, é empregada uma função de perda conhecida como "estimativa de máxima verossimilhança" para estimar o erro entre as saídas previstas e reais. Se a saída estimada para uma instância for superior a 50%, o



modelo prevê a classe positiva; caso contrário, prevê a classe negativa, definindo assim o caráter binário da classificação.

### **2.1.3.2 Support Vector Machine (SVM)**

O algoritmo SVM é projetado para encontrar um hiperplano ótimo que separa efetivamente os dados em classes distintas. Este algoritmo é caracterizado pelo seu foco em vetores de suporte, pontos de dados específicos que são essenciais para definir a posição e orientação do hiperplano decisivo. A maximização da margem, a distância entre o hiperplano de separação e os vetores de suporte, é uma característica chave da SVM, refletida no conceito de "hard margin" (Prinzi et al., 2024).

Entretanto, em alguns casos, é necessário permitir certo erro de classificação para melhorar a capacidade de generalização do modelo, o que leva ao conceito de "soft margin". A gestão dessa flexibilidade é controlada pelo parâmetro de regularização  $C$ , que ajusta o trade-off entre maximizar a margem e minimizar o erro de treinamento. Um valor menor de  $C$  indica uma tolerância maior para com os erros de classificação durante o treinamento, favorecendo a generalização, enquanto um valor maior de  $C$  foca na precisão do modelo nos dados de treinamento, potencialmente às custas da generalização (Prinzi et al., 2024).

Nos casos em que os dados não são linearmente separáveis, o algoritmo SVM utiliza o truque do kernel para projetar os dados em uma dimensão mais alta, onde se tornam separáveis. Esta etapa é fundamental, pois a escolha do kernel adequado afeta diretamente a distribuição dos dados no novo espaço e, por consequência, o desempenho da classificação (Prinzi et al., 2024).

### **2.1.3.3 Redes Neurais Convolucionais (CNN)**

Prinzi et al. (2024) explicam que as redes neurais convolucionais (CNNs) são essenciais na análise de imagens devido à sua capacidade de integrar a extração de características diretamente em seu processo de análise, tornando-as particularmente interessantes para aplicações em imagens médicas. A arquitetura de uma CNN é composta por camadas sequenciais que incluem camadas de convolução e de pooling. As camadas de convolução aplicam filtros ajustáveis que permitem à rede aprender a identificar características específicas, como texturas ou bordas, enquanto

as camadas de pooling ajudam a reduzir a dimensionalidade dos dados, aumentando a eficiência do processo de aprendizado. Esse arranjo permite que as CNNs processem informações desde o nível mais básico até características complexas e abstratas, cruciais para a classificação eficaz de imagens.

#### **2.1.3.4 K-Nearest Neighbors**

A abordagem KNN é um dos métodos de classificação mais simples, nos quais o algoritmo encontra os  $k$  exemplos mais próximos no conjunto de treinamento para atribuir a classe aos novos dados. O processo de treinamento envolve o cálculo das distâncias entre os pontos de dados, e quando novos dados são introduzidos, essas distâncias precisam ser recalculadas. O algoritmo requer a definição de três hiperparâmetros principais: a cardinalidade do vizinho, que define quantos vizinhos serão verificados para a atribuição de classe, a métrica para estimar a distância entre os pontos vizinhos e a função de peso para atribuir um peso de acordo com a distância. O núcleo desse classificador depende principalmente da escolha da métrica para calcular a distância entre os exemplos testados e os exemplos de treinamento. (Prinzi et al., 2024)

#### **2.1.3.5 Random Forest**

Este algoritmo treina múltiplas árvores de decisão, cada uma considerando um subconjunto aleatório dos dados, e melhora a estabilidade e a precisão através de um mecanismo de votação das árvores. É útil em casos de dados ausentes e ruidosos, com a configuração do número de estimadores sendo um hiperparâmetro importante (Prinzi et al., 2024).

O estudo explora o uso desse algoritmo para treinar múltiplas árvores de decisão (DTs), utilizando uma técnica chamada bagging, que permite o treinamento de cada DT em uma porção aleatória do conjunto de dados. Esse método gera resultados variados para cada DT individual, pois elas são treinadas com dados e características diferentes. A agregação das previsões de todas as DTs através de um mecanismo de votação é o que confere ao RF sua robustez, melhorando a estabilidade e a acurácia do modelo. Um hiperparâmetro chave no RF é o número de estimadores, que é o número de DTs na floresta, e embora não haja uma regra geral para definir esse número, outro parâmetro importante é o número máximo de

características usadas no treinamento de cada DT. O RF é considerado adequado para casos com dados ausentes ou com ruído.

## **2.2 Trabalhos Anteriores**

Neste capítulo, será apresentado alguns estudos já realizados na detecção de fadiga, mostrando seus achados e suas contribuições para esse estudo.

### **2.2.1 Tecnologias de Monitoramento**

A importância e o impacto das tecnologias vestíveis na detecção da fadiga cognitiva são destacados por Varandas et al. (2022). Utilizando dispositivos *fNIRS* vestíveis junto com algoritmos de aprendizado de máquina, este estudo visa detectar automaticamente estados de fadiga cognitiva. As tecnologias vestíveis oferecem a vantagem de monitorar os pacientes de maneira não intrusiva, permitindo a coleta de dados em tempo real em ambientes naturais. Esse avanço abre caminho para monitoramentos cognitivos contínuos, facilitando intervenções personalizadas e mais efetivas.

No estudo, procedimentos experimentais foram conduzidos para induzir a fadiga cognitiva efetivamente, através de uma aula digital e tarefas cognitivas padrão. Através dos dispositivos *fNIRS*, os dados fisiológicos dos participantes foram coletados e, posteriormente, analisados com algoritmos de machine learning, alcançando uma precisão de classificação de aproximadamente 70,91%. Esses resultados evidenciam o potencial da combinação dos dispositivos vestíveis *fNIRS* com o aprendizado de máquina para uma detecção precisa e individualizada da fadiga cognitiva.

A adaptabilidade dessas tecnologias às dinâmicas individuais dos usuários, sem a necessidade de equipamentos complexos ou ambientes especializados, marca um avanço significativo para sua aplicação em cenários reais, como o e-learning, entre outros contextos de aprendizado. Esta abordagem não só melhora a eficácia do monitoramento da fadiga cognitiva, mas também suporta o desenvolvimento de intervenções personalizadas, otimizando o processo de aprendizado e a produtividade, ao mesmo tempo em que minimiza o risco de sobrecarga cognitiva.

O estudo conduzido por Hayat et al. (2022) aborda o desafio do reconhecimento de atividades humanas em idosos, utilizando algoritmos de aprendizado de máquina e aprendizado profundo. Com o envelhecimento, a capacidade física e a autonomia para realizar tarefas diárias tendem a diminuir, afetando a saúde física e mental dos idosos. Diante disso, a pesquisa propõe um sistema de monitoramento assistido que emprega dados de acelerômetro e giroscópio coletados de smartphones para reconhecer atividades rotineiras, como se sentar, andar, subir escadas, entre outras.

O estudo destaca o papel crucial dos smartphones como dispositivos de monitoramento acessíveis e robustos, que, aliados a algoritmos como *K-Nearest Neighbors*, *Random Forest*, *Support Vector Machine*, *Artificial Neural Network*, e *Long Short-Term Memory* (LSTM), alcançam uma precisão notável na identificação de atividades. Especificamente, o modelo LSTM apresentou a melhor precisão, atingindo 95,04% de acurácia. Este desempenho exemplifica o potencial do uso de tecnologias vestíveis e de aprendizado de máquina para aprimorar o cuidado e o suporte aos idosos, promovendo uma maior independência e segurança.

### **2.2.2 Abordagens para detecção de fadiga**

Hooda et al. (2022) oferecem uma revisão abrangente sobre métodos de detecção de fadiga utilizando técnicas de aprendizado de máquina, destacando a crescente prevalência da fadiga em um mundo em rápida transformação e a necessidade de abordagens eficazes para sua detecção. Eles introduzem e discutem métodos e avanços recentes na detecção de fadiga, categorizando as abordagens em modelos matemáticos, implementações baseadas em regras, aprendizado de máquina e aprendizado profundo. A revisão compara e contrasta vários algoritmos para identificar a abordagem mais promissora para a detecção de fadiga, destacando áreas para melhorias futuras.

Dentre as abordagens de detecção de fadiga, os métodos de aprendizado de máquina e aprendizado profundo apresentam-se como promissores, abrangendo o monitoramento de sinais eletroencefalográficos (EEG), detecção de bocejos, análise de músculos faciais, detecção de sonolência e identificação de pupilas, com o EEG sendo particularmente notável pela sua eficácia na detecção de padrões de sono e, por consequência, na detecção de fadiga.

Por fim, a revisão conclui que aprendizado de máquina e aprendizado profundo podem ser úteis tanto na detecção quanto no diagnóstico da fadiga, potencializando o avanço do setor de saúde. O artigo apresenta uma revisão detalhada das descobertas de pesquisa relacionadas à detecção de fadiga, destacando o caminho para futuras inovações na área.

O estudo de Gao et al. (2023) investigou o impacto da fadiga induzida por corrida na distribuição da força plantar nos pés dominante e não dominante de corredores amadores. Utilizando medidas pedobarográficas, o estudo objetivou facilitar o reconhecimento automático da marcha fatigada por meio de modelos de rede neural convolucional (CNN) e rede neural de longo-curto prazo baseada em CNN (ConvLSTM). A coleta de dados da força plantar foi realizada antes e após um protocolo de indução de fadiga em corrida, usando uma placa de força *FootScan*, e os dados foram analisados com os modelos de aprendizado profundo implementados na biblioteca Keras do Python.

Os resultados demonstraram que, após a fadiga, ocorreu um aumento significativo da força na região do meio do pé anterior e do calcanhar durante a plantar bilateral, com uma diminuição da força na região média do pé no membro dominante. O modelo ConvLSTM mostrou desempenho superior (acurácia= 0.867, sensibilidade= 0.874 e especificidade= 0.859) na detecção da marcha fatigada em comparação com o modelo CNN (acurácia= 0.800, sensibilidade= 0.874 e especificidade= 0.718). Esses achados podem oferecer dados empíricos para avaliar fatores de risco associados a lesões por uso excessivo em um único membro, além de facilitar a detecção precoce da marcha fatigada.

A abordagem deste estudo, utilizando pedobarografia e modelos de aprendizado profundo, indica um caminho promissor para o monitoramento e a intervenção precoce na fadiga induzida por corrida, contribuindo para a prevenção de lesões e a otimização do treinamento de corredores amadores.

### **2.2.3 Séries Temporais na detecção de fadiga**

O estudo de Hajifar et al. (2020) destaca a aplicação de métodos de séries temporais para prever a fadiga física, um passo essencial na ergonomia e na segurança do trabalho. As séries temporais, que analisam dados ao longo do tempo para identificar padrões e prever eventos futuros, são particularmente úteis na

detecção da fadiga, permitindo intervenções preventivas antes que a fadiga afete negativamente o desempenho e a segurança.

O estudo compara cinco modelos de previsão de séries temporais — métodos ingênuos, autoregressivos (AR), autoregressivos integrados de médias móveis (ARIMA), autoregressão vetorial (VAR) e modelo de correção de erro vetorial (VECM) — usando dados de percepção subjetiva de esforço (RPE) e dados de marcha de sensores vestíveis. O modelo VECM, que integra dados históricos de RPE e de sensores vestíveis, superou os demais modelos, fornecendo previsões precisas para até três períodos à frente, com um erro médio absoluto (MAE) inferior a 1,24 em todos os participantes.

A capacidade dos dados de sensores vestíveis de melhorar significativamente a precisão das previsões de fadiga destaca a importância dessas tecnologias na previsão da condição do trabalhador. O sucesso do modelo VECM em fornecer previsões precisas demonstra o potencial das séries temporais e dos sensores vestíveis em monitorar e intervir na fadiga antes que ela comprometa a segurança e o desempenho.

O estudo conduzido por Biró et al. (2024) explora o uso de Unidades de Medição Inercial (IMUs) e inteligência artificial para monitorar e otimizar ciclos de treinamento de atletas, visando equilibrar desempenho esportivo de alta performance com o controle adequado de fadiga e resistência. Este estudo destaca-se por sua abordagem inovadora na coleta e análise de dados multivariados de séries temporais, gerados por IMUs, para prever níveis de fadiga e ajustar as rotinas de treinamento de forma individualizada.

Utilizando IMUs acopladas a 19 atletas, os pesquisadores registraram aceleração triaxial, velocidade angular e orientação magnética ao longo de sessões repetidas, que incluíam corridas de ritmo constante e técnicas indutoras de fadiga. Dados brutos das séries temporais foram empregados para treinar um modelo de aprendizado de máquina supervisionado, baseado em características de domínio de frequência e tempo. Foram comparados os desempenhos de modelos *Random Forest*, *Gradient Boosting Machines* e redes LSTM, com um loop de feedback ajustando o modelo em tempo real baseado em erro de previsão e estimativa de viés.

O modelo demonstrou alta precisão preditiva para fadiga, exibindo correlações significativas entre os níveis de fadiga previstos e os declínios observados no desempenho. As previsões de resistência possibilitaram ajustes de treinamento individualizados, sincronizados com os limiares fisiológicos dos atletas. Mecanismos de correção de viés se mostraram eficazes na minimização de erros de previsão sistemáticos. Adaptações em tempo real do modelo conduziram a estratégias de periodização de treinamento aprimoradas, reduzindo o risco de treinamento excessivo e melhorando o desempenho atlético geral.

O estudo conclui que o modelo assistido por IA utilizando dados multivariados de séries temporais gerados por IMU, é eficaz na análise de desempenho esportivo. O treinamento pode ser personalizado e constantemente alterado, pois o modelo prevê com precisão a fadiga e a energia. O modelo de IA pode prever efetivamente o início da fadiga antes que sintomas físicos se manifestem, permitindo intervenções oportunas para evitar treinamento excessivo e possíveis acidentes. Ele exibe uma boa capacidade de personalizar programas de treinamento de acordo com as reações fisiológicas de cada atleta, melhorando a eficácia geral do treinamento. Além disso, o estudo demonstrou a eficácia do modelo em monitorar o desempenho em tempo real, aprimorando a capacidade de tomada de decisão de treinadores e atletas.

## **CAPÍTULO 3 - MÉTODO DE PESQUISA**

### **3.1 Caracterização da Pesquisa**

Para alcançarmos nossos objetivos descritos anteriormente, iremos utilizar o método de experimentação respondendo a seguinte hipótese:

- É possível utilizar técnicas de aprendizado de máquina para prever a ocorrência de fadiga em idosos.

Para isso iremos utilizar os algoritmos estado da arte na base descrita acima, onde iremos comparar as acurácias dos modelos e seus custos computacionais.

### **3.2 Método de Pesquisa**

**Formulação da Hipótese:** Levando nossa hipótese como verdade, esperamos encontrar pelo menos um algoritmo de aprendizado de máquina que possua uma acurácia suficientemente boa e um custo computacional razoavelmente pequeno para concluirmos a hipótese como verdade.

**Definição das Variáveis:** As variáveis do trabalho serão os algoritmos estado da arte de classificação em séries temporais onde iremos comparar suas métricas de desempenho, sendo taxa de acerto e tempo de processamento.

**Desenho do Experimento:** Os classificadores escolhidos serão treinados e avaliados utilizando as mesmas pessoas disponibilizadas pela base analisando as mesmas linhas do tempo em que iremos avaliar a eficácia de cada classificador entre eles para definirmos quais poderíamos utilizar para confirmar a hipótese.



## CAPÍTULO 4 - INFORMAÇÕES DA PESQUISA

### 4.1 Cronograma

Para a organização desse trabalho, foi feito o cronograma de mês a mês destacando os objetivos gerais que temos que alcançar em cada mês para conseguir realizar este trabalho no tempo estipulado para ele.

**Tabela 4-1. Planejamento após apresentação da Proposta. Fonte: os Autores**

Mês	Objetivo Geral
<b>Março</b>	1. Construção do Cronograma 2. Início da Proposta do Trabalho
<b>Abril</b>	1. Finalização da Proposta do Trabalho. 2. Preparação para Apresentação 3. Reorganização de Pontos Faltantes na Proposta do Trabalho
<b>Maió</b>	1. Finalização da Visualização dos Pontos da Base e Excel para Anotação de Dados. 2. Início do Projeto de Pesquisa 3. Verificação da Efetividade das Anotações Realizadas
<b>Junho</b>	1. Finalização do Projeto de Pesquisa 2. Montagem de Primeiro Protótipo
<b>Julho</b>	1. Finalização de Pontos de Meses Anteriores
<b>Agosto</b>	1. Análise Exploratória da Base 2. Montagem dos primeiros Pipeline de Aprendizados de Máquina 3. Início da Escrita da Pesquisa Científica
<b>Setembro</b>	1. Rodada de Treino e Testes do Classificadores Escolhidos 2. Análise dos Resultados encontrados
<b>Outubro</b>	1. Finalização da Escrita da Pesquisa Científica 2. Preparação da Apresentação do Trabalho Final
<b>Novembro</b>	1. Finalização de Pontos de Meses Anteriores

Como mostrado na tabela, em março foi montado esse cronograma e seu deu início a essa proposta.

Em abril, é planejado finalizar essa proposta com as revisões do orientador, a montagem da apresentação junto com apresentações teste para preparar a equipe, por fim após a apresentação do trabalho e correções dos professores, será realizado as devidas revisões nesse trabalho.

Em maio, planeja-se finalizar a visualização dos pontos da base e dos Excel que serão utilizados pelos elaboradores da base para realizar a anotação dos dados, complementando sua informação. Após isso, será dado início Ao Projeto de Pesquisa.

Por fim será verificado se as visualizações criadas foram efetivas para anotações de dados e se é possível criar um protótipo do trabalho com as informações adquiridas.

Em junho, será finalizado o Projeto de Pesquisa onde também terá o protótipo necessário para essa entrega e será montado a apresentação com realização de apresentação teste com a equipe.

Em julho, será utilizado o tempo para finalizar quaisquer pontos que tenha ficado incompleto dos meses passados.

Em agosto, será realizado a análise exploratória onde nela procuraremos alcançar o primeiro objetivo específico desse trabalho, especificado na introdução. Com essa análise será montado as pipelines de pré-processamentos necessários para os algoritmos de aprendizado de máquina.

Por fim, será iniciado a escrita da Pesquisa Científica, principalmente, dos resultados da análise exploratória e os pré-processamentos que serão realizados.

Em setembro, será realizado as rodadas de treino e teste dos algoritmos de aprendizado de máquina e será analisado seus resultados para visualizar se foi alcançado o objetivo principal desse trabalho.

Em outubro, será finalizado a Pesquisa Científica, adicionando os resultados encontrados no mês anterior e as conclusões que forem encontradas desses resultados. Com a Pesquisa Científica finalizada, será montada a apresentação final desse trabalho com mais apresentações teste para preparação da equipe.

Em novembro, terá seu tempo utilizado para tópicos faltantes nos meses anteriores.

## 4.2 Riscos

Para que este trabalho seja finalizado sem problemas, foram detalhados abaixo os riscos desse projeto, onde detalhamos sua probabilidade, impacto, severidade, ações de prevenção e ações de contingência.

**Tabela 4-2. Riscos do projeto. Fonte: os Autores.**

<b>Id</b>	<b>Descrição</b>	<b>P</b>	<b>I</b>	<b>S</b>	<b>Ação de Prevenção</b>	<b>Ação de Contingência</b>
<b>1</b>	Falha na Classificação da Base	Baixa	Alto	3	Auxiliar na classificação da base e procurar	Utilizar algoritmos de aprendizado de máquina que possam

					mais pessoas para realizarem a anotação	realizar a detecção de mudança da série temporal ao invés de classificadores
2	Falta de Tempo	Baixa	Alta	3	Procurar separar as tarefas de forma igual para todos os integrantes, não criar cronogramas com muitas tarefas e programar períodos para finalizar tarefas pendentes	Procurar auxílio com outras pessoas que possam acelerar o processo e diminuir a necessidade de tempo
3	Falta de Conhecimento em Classificadores de Series Temporais	Baixa	Baixa	1	Procurar outros trabalhos que já utilizaram esses classificadores e procurar ler os tutoriais disponibilizados na internet	Procurar auxílio com outras pessoas que já tenham trabalhado com esses classificadores e possam auxiliar no trabalho
4	Algoritmos de Aprendizado de Máquina necessitando de mais tempo do que esperado para seu treino e teste	Médio	Médio	4	Procurar simplificar o que for possível da rodada de treino e teste a ser realizada dos algoritmos	Procurar auxílio com outras pessoas que possuam máquinas mais potentes e que tenham interesse em auxiliar no trabalho.

Legenda P: probabilidade (alta, média, baixa)

I: impacto (alto, médio, baixo)

S: severidade ( $S=P*I$ )

O risco de falha na classificação na base, pode ocorrer no caso de não for concluída a classificação dos dados ou houver classes incorretas na base. As chances desse risco ocorrer são baixas visto que as pessoas que estão responsáveis pela ação são bem capacitadas para o serviço, mas para evitar isso, a equipe irá auxiliar no máximo possível e se visto necessário encontrar mais pessoas para auxiliar. Caso ocorra essa falha pode-se utilizar de algoritmos de aprendizagem de máquina para realizar a classificação. Caso não seja concluída a classificação existe um alto risco para com o projeto, pois sem os dados categorizados, não será possível aplicar os métodos de detecção de séries temporais.

Os riscos por falta de tempo, pode ocorrer pelo grupo não conseguir alcançar os prazos existentes devido à falta de tempo dos membros da equipe ou ao atraso de alguma atividade. Devido à como está a situação atual do projeto, é baixa a chance de ocorrer o atraso, já que foi feito de modo mais balanceada a separação de tarefas e reservado tempo para tarefas faltantes no cronograma. Caso ocorra a

falta de tempo será buscado mais pessoas que possam ajudar o desenvolvimento das atividades. O impacto de falta de tempo é grande, visto que isso afeta diretamente a conclusão do projeto.

Outro possível risco é a falta de conhecimento da equipe em relação aos classificadores de séries temporais, que é considerado baixo, visto que já está marcado no planejamento do grupo estudar sobre o assunto. Caso a dificuldade se mantenha após esse estudo programa, será buscado pessoas que já tenham trabalhado com os algoritmos para auxiliar no desenvolvimento. Foi considerado baixo este risco, já que existem diversas fontes para o grupo estudar sobre o assunto.

Existe também o risco de os algoritmos de aprendizado de máquina levarem mais tempo do que o imaginado para concluírem seus cálculos, que foi previsto como mediano, devido ao tamanho da base ser extensa, mas o patamar da tecnologia de hoje facilita ainda que se tenha uma base grande para trabalhar. Contudo para evitar será realizada a simplificação de alguns algoritmos durante a rodada de treino e testes. Caso ainda ocorra atrasos, será buscado auxílio de pessoas que possuam computadores com uma maior potência de cálculo e estejam dispostas a ajudar disponibilizando o equipamento. No caso de os algoritmos levarem mais tempo que esperado será gerado um impacto de proporções moderadas, visto que causará atrasos pequenos.

## REFERÊNCIAS BIBLIOGRÁFICAS

MOTA, Dálete Delalibera Corrêa de Faria; CRUZ, Diná de Almeida Lopes Monteiro da; PIMENTA, Cibele Andrucio de Mattos. Fadiga: uma análise do conceito. *Acta Paulista de Enfermagem*, v. 18, p. 285-293, 2005.

ADÃO MARTINS, Neusa R.; ANNAHEIM, Simon; SPENGLER, Christina M.; ROSSI, René M. (2021). Fatigue Monitoring Through Wearables: A State-of-the-Art Review. *Frontiers in Physiology*, v. 12, artigo 790292. Disponível em: <https://doi.org/10.3389/fphys.2021.790292>. Acesso em: 07 abr. 2024.

GAO, Z.; XIANG, L.; FEKETE, G.; BAKER, J. S.; MAO, Z.; GU, Y. (2023). A Data-Driven Approach for Fatigue Detection during Running Using Pedobarographic Measurements. *Applied Bionics and Biomechanics*. Disponível em: <https://doi.org/10.1155/2023/7022513>. Acesso em: 08 abr. 2024.

HAJIFAR, S.; SUN, H.; MEGAHED, F. M.; JONES-FARMER, L. A.; RASHEDI, E.; CAVUOTO, L. A. (2020). A Forecasting Framework for Predicting Perceived Fatigue: Using Time Series Methods to Forecast Ratings of Perceived Exertion with Features from Wearable Sensors. *Applied Ergonomics*. Disponível em: <https://doi.org/10.1016/j.apergo.2020.103262>. Acesso em: 08 abr. 2024.

HAYAT, A.; MORGADO-DIAS, F.; BHUYAN, B.P.; TOMAR, R. Human Activity Recognition for Elderly People Using Machine and Deep Learning Approaches. *Information*, v. 13, p. 275, 2022. Disponível em: <https://doi.org/10.3390/info13060275>. Acesso em: 07 de abr. 2024.

HOODA, R.; JOSHI, V.; SHAH, M. (2022). A comprehensive review of approaches to detect fatigue using machine learning techniques. *Chronic Diseases and Translational Medicine*, 8: 26–35. Disponível em: <https://doi.org/10.1016/j.cdtm.2021.07.002>. Acesso em: 08 de abr. de 2024.

MURRAY, C.; CHAURASIA, P.; HOLLYWOOD, L.; COYLE, D. (2022). A Comparative Analysis of State-of-the-Art Time Series Forecasting Algorithms. Disponível em: <https://ieeexplore.ieee.org/document/10216678>. Acesso em: 07 abr. 2024.

VARANDAS, R.; LIMA, R.; BERMÚDEZ I BADIA, S.; SILVA, H.; GAMBOA, H. (2022). Automatic Cognitive Fatigue Detection Using Wearable fNIRS and Machine Learning. *Sensors*, v. 22, n. 11, p. 4010. Disponível em: <https://doi.org/10.3390/s22114010>. Acesso em: 07 abr. 2024.

BIRÓ, A.; CUESTA-VARGAS, A.I.; SZILÁGYI, L. (2024). AI-Assisted Fatigue and Stamina Control for Performance Sports on IMU-Generated Multivariate Times Series Datasets. *Sensors*, 24, 132. Disponível em: <https://doi.org/10.3390/s24010132>. Acesso em: 08 abr. 2024.

PRINZI, F.; CURRIERI, T.; GAGLIO, S.; VITABILE, S. (2024). Shallow and Deep Learning Classifiers in Medical Image Analysis. *European Radiology Experimental*, 8(26). Disponível em: <https://doi.org/10.1186/s41747-024-00428-2>. Acesso em: 13 abr. 2024.

## GLOSSÁRIO

**APÊNDICE A – TÍTULO DO APÊNDICE A**

[OptiTrack Documentation | v3.1 | EXTERNAL OptiTrack Documentation](#) -

Documentação do Programa OptiTrack