

Enzo Ramon Campa, Jasmini Rebecca Gomes dos Santos e
Leandro Ceron Durau

DETECÇÃO DE FADIGA EM IDOSOS UTILIZANDO
SÉRIES TEMPORAIS
- PROPOSTA DE PESQUISA CIENTÍFICA -

Trabalho de Conclusão de Curso apresentado ao curso de Bacharelado em Ciência da Computação da Pontifícia Universidade Católica do Paraná como requisito parcial para obtenção do título de Cientista da Computação.

Área de concentração: Ciência da Computação

Orientador: Professor André Gustavo Hochuli

Curitiba
2024

Enzo Ramon Campa, Jasmini Rebecca Gomes dos Santos e
Leandro Ceron Durau

DETECÇÃO DE FADIGA EM IDOSOS UTILIZANDO
SÉRIES TEMPORAIS
- PROPOSTA DE PESQUISA CIENTÍFICA -

Trabalho de Conclusão de Curso apresentado ao curso de Bacharelado em Ciência da Computação da Pontifícia Universidade Católica do Paraná como requisito parcial para obtenção do título de Cientista da Computação.

Área de concentração: Ciência da Computação

Orientador: Professor André Gustavo Hochuli

Curitiba
2024

RESUMO

Com o aumento do número de idosos na população, os profissionais de saúde têm focado seus esforços em como manter a qualidade de vida dessa população. Um desses esforços é na detecção de fadiga, da qual pode ser utilizada para evitar a possível ocorrência de várias enfermidades nessas pessoas. Para auxiliar nesse estudo, este trabalho apresentará uma nova base de dados contendo as coordenadas de vários pontos do corpo de vinte idosos que realizavam um exercício até a ocorrência de fadiga. Com essa base, será realizado a análise exploratória da base para entender quais sinais o corpo humano demonstra ao estar cansado e será usado técnicas de Aprendizado de Máquina em Séries Temporais para prever o acontecimento da fadiga nos idosos

Palavras-chaves: Séries Temporais, Fadiga, Aprendizado de Máquina, Previsão, Idosos.

ABSTRACT

With the increase of the number of elderly people in the population, the health professionals have been focusing their efforts on how to maintain the healthy quality of that population. One of those efforts is the detection of fatigue that it can be used to prevent the possible occurrence of various health problems in this people. To help in this study this work presents a new dataset with the coordinates of various points in the body of twenty elderly subjects doing an exercise until the occurrence of fatigue. With this dataset, it will be produced an exploratory analysis to understand what signals the body presents when they start getting tired, and it will be used machine learning techniques on time series to forecast the occurrence of fatigue on the elderly people.

Keywords: Time Series, Fatigue, Machine Learning, Forecast, Elderly People.

SUMÁRIO

RESUMO.....	III
ABSTRACT	IV
LISTA DE FIGURAS.....	VII
LISTA DE TABELAS	VIII
LISTA DE QUADROS	IX
LISTA DE ABREVIATURAS E SIGLAS	X
CAPÍTULO 1 - INTRODUÇÃO.....	1
1.1 INTRODUÇÃO	1
1.2 OBJETIVOS	5
1.3 ESTRUTURA DO DOCUMENTO.....	6
CAPÍTULO 2 - FUNDAMENTAÇÃO TEÓRICA.....	7
2.1 CONCEITOS BÁSICOS DE FADIGA	7
2.2 SÉRIES TEMPORAIS	8
2.3 CLASSIFICADORES DE MACHINE LEARNING	9
2.3.1 Regressão Logística.....	9
2.3.2 Support Vector Machine (SVM).....	9
2.3.3 Redes Neurais Convolucionais (CNN).....	10
2.3.4 K-Nearest Neighbors.....	11
2.3.5 Random Forest.....	11
CAPÍTULO 3 - REVISÃO DA LITERATURA	12
3.1 TECNOLOGIAS DE MONITORAMENTO	12
3.2 ABORDAGENS PARA DETECÇÃO DE FADIGA	13
3.3 SÉRIES TEMPORAIS NA DETECÇÃO DE FADIGA	14
CAPÍTULO 4 - MÉTODO DE PESQUISA.....	17
4.1 CARACTERIZAÇÃO DA PESQUISA	17
4.2 MÉTODO DE PESQUISA.....	17
CAPÍTULO 5 - VALIDAÇÃO DA PESQUISA CIENTÍFICA.....	19
5.1 BASE DE DADOS.....	19

5.2	VALIDAÇÃO DA PESQUISA.....	19
5.3	TESTES EXECUTADOS	20
CAPÍTULO 6 - INFORMAÇÕES DA PESQUISA		25
6.1	CRONOGRAMA.....	25
6.2	RISCOS	26
REFERÊNCIAS BIBLIOGRÁFICAS.....		29
GLOSSÁRIO		31
APÊNDICE A – TÍTULO DO APÊNDICE A.....		32

LISTA DE FIGURAS

Figura 1-1. Imagem representando exercício realizado pelos idosos, adaptado de https://blogeducacaofisica.com.br/exercicios-funcionais-para-idosos/	2
Figura 1-2. Gráfico demonstrando o movimento do ponto LFTC da base ao decorrer do tempo da coleta.....	3
Figura 1-3. Imagem mostrando a localização exata dos pontos no corpo humano, adaptado de https://v21.wiki.optitrack.com/index.php?title=Biomechanics_Markersets	5
Figura 4-1: Imagem representando janela 1 para 1 Fonte: https://www.tensorflow.org/tutorials/structured_data/time_series?hl=pt-br	21
Figura 4-2: Imagem representando janela 3 para 1 Fonte: https://www.tensorflow.org/tutorials/structured_data/time_series?hl=pt-br	22
Figura 4-3: Imagem representando janela 24 para 24 Fonte: https://www.tensorflow.org/tutorials/structured_data/time_series?hl=pt-br	23
Figura 4-4: Resultado apresentado nos testes realizados Fonte: Os Autores	24

LISTA DE TABELAS

Tabela 1-1. Tabela com todos os pontos do corpo que foram mapeados na base desse trabalho	4
Tabela 5-1. Planejamento após apresentação da Proposta. Fonte: os Autores	25
Tabela 5-2. Riscos do projeto. Fonte: os Autores.	26

LISTA DE QUADROS

Quadro 4-1: Código utilizado para realizar tratar os dados faltantes Fonte: Os Autores	20
--	----

LISTA DE ABREVIATURAS E SIGLAS

SIGLA	SIGNIFICADO
PPGTS	Programa de Pós-Graduação em Tecnologia da Saúde
PUCPR	Pontifícia Universidade Católica do Paraná
LSTM	Long Short-Term Memory
EEG	Monitoramento de sinais Eletroencefalográficos
CNN	Rede Neural Convolucional
AR	Autorregressivo
ARIMA	Autorregressivo Integrados de Médias Móveis
VAR	Autorregressivo Vetorial
VECM	Modelo de Correção de Erro Vetorial
RPE	Percepção Subjetiva de Esforço
MAE	Erro Médio Absolute
IMUs	Unidades de Medição Inercial

CAPÍTULO 1 - INTRODUÇÃO

1.1 Introdução

Atualmente, por causa do aumento na qualidade de vida, tem-se observado um aumento significativo na população mais idosa. Isso tem sido uma grande preocupação do mundo da saúde, já que essa, pela sua idade mais avançada, tem mais suscetibilidade a doenças e a lesões, tendo em conta sua menor resistência física e imunológica. Da qual aumentam as chances de ter problemas de saúde severos como demência, paralisia, perda de movimento ou até a morte.

Com essa preocupação em mente, muitos médicos têm se esforçado para descobrir como tratar essa população mais idosa e permitir que consigam continuar a viver suas vidas normalmente. Uma dessas preocupações tem sido a fadiga.

Segundo Mota, Cruz e Pimenta (2005) ¹, os principais atributos relacionados a fadiga são cansaço, exaustão, desgaste, alteração da capacidade funcional e falta de recursos/energia. Essas características por si, já podem causar inúmeros problemas de saúde independentemente da idade, contudo os idosos, levando em consideração os pontos levantados acima, podem ser bem mais propícios a essas enfermidades.

Para exemplificarmos o ponto acima, imagine que uma pessoa jovem adulta saudável acabe sentido fadiga e acabe sofrendo uma queda. Pela sua maior resistência, essa somente sofrerá alguns arranhões em seu corpo e precisará de alguns minutos descansando para poder se recompor e conseguir continuar seu caminho.

Já quando comparado a um idoso saudável que acabe sentido fadiga e sofra uma queda. Pela sua maior idade, poderá sofrer uma fratura em seus ossos, que pode causar cortes em seus órgãos e uma hemorragia interna. Além disso pela sua possível falta de força, possa não conseguir se levantar, necessitando de ajuda de outros.

Com esses pontos em mente, é possível visualizar a importância que a área da saúde possui na fadiga ocorrida em idosos, focando principalmente em como

pode-se detectá-la antes de ocorrer uma queda, da qual, como anteriormente demonstrada pode causar inúmeras enfermidades perigosas a vida do idoso.

Com isso em mente, pretende-se com esse trabalho detectar a ocorrência dessa fadiga em idosos utilizando técnicas de aprendizado de máquina.

Para isso, realizaremos uma parceria com o Programa de Pós-Graduação em Tecnologia da Saúde (PPGTS) da Pontifícia Universidade Católica do Paraná (PUCPR), composta pelo Professor Eduardo Mendonça Scheeren e a Mestranda Rafaela Machado, os quais são os elaboradores da base que será explicada abaixo.

Essa base foi composta com ajuda do programa OptiTrack, um programa feito para capturar a movimentação de pessoas, com auxílio de câmeras e roupa utilizada pelas pessoas para destacar pontos do corpo. Onde o aplicativo mapeia a posição de vários pontos do corpo humano para criar um esqueleto virtual que realiza a movimentação capturada.

Com o programa, foi selecionado 20 candidatos idosos, 11 do sexo feminino e 9 do sexo masculino, do qual realizaram o exercício de se levantar e se sentar repetidamente até o idoso se sentir indisposto a continuar o exercício ou a coleta fosse parada. Esses exercícios eram feitos em ritmos definidos por sinais sonoros que aumentavam seu ritmo ao decorrer da coleta.



Figura 1-1. Imagem representando exercício realizado pelos idosos, adaptado de <https://blogeducacaofisica.com.br/exercicios-funcionais-para-idosos/>

Com essa coleta, foi construída a base que será utilizada nesse trabalho, onde apresenta-se as localizações (X, Y, Z) de vários pontos do corpo ao decorrer da coleta, ou seja, a base é uma série temporal da movimentação do corpo do idoso.




Figura 1-2. Gráfico demonstrando o movimento do ponto LFTC da base ao decorrer do tempo da coleta

A tabela abaixo mostra todos os 57 pontos do corpo humano mapeados na base desse trabalho

Sigla	Nome
LAH	Left Anterior Head
RAH	Right Anterior Head
LPH	Left Posterior head
RPH	Right Posterior head
SJN	Sternum Jugular Notch
SXS	Sternum Xiphoid Process
CV7	Cervical Spine Vertebra 7
TV2	Thoracic Spine Vertebra 2
TV7	Thoracic Spine Vertebra 7
LHGT	Left Glenohumeral Joint
RHGT	Right Glenohumeral Joint
LIAS	Left Iliac Anterior Spine
RIAS	Rigth Iliac Anterior
LIPS	Left Iliac Posterior Spine
RIPS	Right Iliac Posterior Spine
LCAJ	Left Clavicle-Acromion Joint
RCAJ	Right Clavicle-Acromion Joint
LHLE	Left Humerus Lateral Epicondyl
RHLE	Right Humerus Lateral Epicondyle
LHME	Left Humerus Medial Epicondyle
RHME	Right Humerus Medial Epicondyle
LUA	Left Upper Arm
RUA	Right Upper Arm
LHM2	Left Hand Second metacarpal
RHM2	Right Hand Second metacarpal
LUSP	Left Ulna Styloid Process

RUSP	Right Ulna Styloid Process
LRSP	Left Radius Styloid Process
RRSP	Right Radius Styloid Process
LFTC	Left Femoral greater Trochanter
RFTC	Right Femoral greater Trochanter
LFLE	Left Femur Lateral Epicondyle
RFLE	Right Femur Lateral Epicondyle
LFME	Left Femur Medial Epicondyle
RFME	Right Femur Medial Epicondyle
LTH	Left Thigh
RTH	Right Thigh
LSK	Left Superior Knee
RSK	Right Superior Knee
LTTC	Left Tibial Tubercle
RTTC	Right Tibial Tubercle
LFAX	Left Fibula Apex
RFAX	Right Fibula Apex
LFAL	Left Fibula Ankle Lateral
RFAL	Right Fibula Ankle Lateral
LTAM	Left Talus Ankle Medial
RTAM	Right Talus Ankle Medial
LFM5	Left Foot Fifth Metatarsal
RFM5	Right Foot Fifth Metatarsal
LFM2	Left Foot Second Metatarsal
RFM2	Right Foot Second Metatarsal
LFM1	Left Foot First Metatarsal
RFM1	Right Foot First Metatarsal
LFCC	Left Foot Calcaneus
RFCC	Right Foot Calcaneus
LDP1	Left First Distal Phalanx
RDP1	Right First Distal Phalanx

Tabela 1-1. Tabela com todos os pontos do corpo que foram mapeados na base desse trabalho




Figura 1-3. Imagem mostrando a localização exata dos pontos no corpo humano, adaptado de https://v21.wiki.optitrack.com/index.php?title=Biomechanics_Markersets

Com esses dados, primeiramente, será realizado uma análise exploratória da base com intenção de encontrar padrões que ocorrem na movimentação dos idosos ao começarem a apresentar sintomas de fadigas. Para assim, ser observado quais pontos apresentam mudanças em seu comportamento, dos quais indiquem a ocorrência de fadiga ao longo do tempo.

Após isso será utilizado os algoritmos estados da arte de aprendizado de máquina para séries temporais, assim será possível observar a possibilidade da utilização dessas técnicas de aprendizado de máquina para detectar a fadiga.

1.2 Objetivos

De acordo com os pontos acima tem-se que objetivo geral desse trabalho é:

- Apresentar para a comunidade científica uma nova base de dados de séries temporais rotulada com os pontos de fadiga.
- Apresentar a possibilidade de utilizar técnicas de aprendizado de máquina para séries temporais para prever a ocorrência de fadiga em idosos.

Para isso teremos nossos objetivos específicos:

- Encontrar padrões que representam sintomas de fadiga em dados físicos.

- Avaliar o desempenho de diversos algoritmos, pontuando vantagens e desvantagens de sua utilização.

Com esses objetivos alcançados será possível responder à pergunta de pesquisa que envolve esse trabalho:

- É possível prever a ocorrência de fadiga utilizando técnicas de aprendizado de máquina em séries temporais?

1.3 Estrutura do documento

O capítulo 1, anteriormente apresentado, visa informar o leitor sobre o problema que estamos analisando e como iremos resolvê-lo.

O capítulo 2 aprofunda o referencial teórico descrito no capítulo 1

O capítulo 3 apresenta trabalhos já realizados na área.

O capítulo 4 apresenta o método de pesquisa utilizado para alcançar aos nossos objetivos

O capítulo 5 apresenta como será validado essa pesquisa científica e mais detalhes sobre a base

O capítulo 6 apresenta o planejamento que será seguido nos próximos meses e os riscos que esse projeto possui e suas possíveis ações de contenção e contingência.

CAPÍTULO 2 - FUNDAMENTAÇÃO TEÓRICA

Essa revisão de literatura abrange uma análise dos conceitos de fadiga e as metodologias para sua detecção e monitoramento. Examinam-se as implicações da fadiga na saúde e na produtividade, com ênfase nos idosos, avaliando o papel das tecnologias vestíveis e técnicas de aprendizado de máquina na monitorização dessa condição.

Neste capítulo será apresentado a teoria em mais detalhes dos tópicos apresentados na introdução, sendo esses:

- Fadiga;
- Séries Temporais
- Classificadores de Machine Learning

2.1 Conceitos básicos de fadiga

A fadiga é uma condição caracterizada por um declínio acentuado tanto na capacidade física quanto mental, atribuída a fatores como esforço prolongado, desequilíbrio circadiano, e falta de sono. Segundo Adão Martins et al. (2021), essa condição não somente impacta negativamente a produtividade e eficiência nas atividades laborais, mas também eleva substancialmente o risco de acidentes em ambientes ocupacionais críticos como o setor de transporte. Além disso, a complexidade e a natureza multifacetada da fadiga, influenciada por uma vasta gama de variáveis interconectadas, dificultam a concepção de uma definição unificada e abrangente. Ainda assim, é fundamental reconhecer a fadiga não apenas como uma resposta fisiológica natural do corpo a excessos, mas também como um sintoma associado a diversas doenças e condições de saúde, o que ressalta a importância de sua detecção precoce e cuidado adequado.

Em idosos, a fadiga pode ter impactos significativos na qualidade de vida, uma vez que afeta tanto a capacidade de realizar atividades diárias quanto a função cognitiva, aumentando o risco de quedas, diminuição da independência e potencial deterioração da saúde mental (VARANDAS et al., 2022). A detecção e

monitoramento eficazes da fadiga em idosos são, portanto, essenciais para intervenções oportunas que possam mitigar esses efeitos e promover um envelhecimento saudável.

A aplicação de tecnologias vestíveis e algoritmos de machine learning emerge como uma abordagem promissora na monitorização contínua da fadiga em idosos, possibilitando a detecção precoce de sinais de fadiga física e mental através da análise de dados fisiológicos e de movimento em tempo real (VARANDAS et al., 2022; HAYAT et al., 2022).

2.2 Séries Temporais

Uma série temporal é uma sequência de pontos de dados coletados, registrados ou medidos em intervalos de tempo sucessivos. A capacidade de prever séries temporais é crucial em vários campos, como finanças, meteorologia e vendas, pois permite antecipar futuros valores com base em tendências passadas e presentes. Este aspecto é essencial para a tomada de decisões informadas em ambientes corporativos e governamentais (Murray et al., 2022).

O estudo realizado por Murray et al. oferece uma análise comparativa dos algoritmos de ponta para previsão de séries temporais, destacando a crescente demanda por capacidades de previsão em domínios desafiadores e problemas de análise de dados. As séries temporais, fundamentais para prever valores futuros com base em sequências passadas, têm evoluído significativamente desde as primeiras metodologias de Holt-Winters e Box-Jenkins, passando por modelos estatísticos como ARIMA, até as soluções recentes que incorporam aprendizado profundo.

A pesquisa avalia oito algoritmos de ponta, incluindo LSTM (*Vanilla*, Bidirecional, e com *Autoencoder*), GRU, CNN-LSTM, ConvLSTM, redes com mecanismo de Atenção e a rede *Transformer*, em cinco conjuntos de dados de benchmark abrangendo finanças, meteorologia e vendas. A pesquisa visa determinar se métodos de previsão diretos ou iterativos são ótimos para a previsão, empregando uma estrutura de validação cruzada de 10 *k-folds* com o algoritmo ASHA para otimização de modelo.

Os resultados revelam que, embora existam diferenças entre todos os modelos, as disparidades são insignificantes entre os modelos de melhor

desempenho, que incluem o *Transformer*, Atenção, V-LSTM, CNN-LSTM e CV-LSTM. Notavelmente, o modelo *Transformer* consistentemente produziu o menor erro de previsão, evidenciando sua robustez e versatilidade em uma gama diversificada de aplicações de previsão de séries temporais.

2.3 Classificadores de Machine Learning

Nesta seção, são explorados alguns classificadores de machine learning, fundamentais para previsões e classificações em inteligência artificial. Serão abordadas as características, métodos de implementação e aplicações práticas de cada classificador. Este estudo proporciona uma visão abrangente sobre como esses algoritmos operam em variados contextos de dados.

2.3.1 Regressão Logística

A regressão logística é utilizada para identificar a relação entre variáveis dependentes e independentes, sendo a variável dependente a classe alvo a ser prevista. Esta técnica retorna a probabilidade de uma instância pertencer a uma determinada classe, baseada na função logística, que minimiza o erro e limita a saída entre 0 e 1. Devido à sua implementação simples e à falta de necessidade de ajuste crítico de hiperparâmetros, a regressão logística é amplamente utilizada em contextos clínicos (Prinzi et al., 2024).

Em particular, o artigo enfatiza que a função logística, ou função sigmoide, é usada como a função de separação, adequando-se à curva dos pontos de dados para minimizar o erro e comprimir a saída de uma equação linear entre 0 e 1. Durante o processo de treinamento, é empregada uma função de perda conhecida como "estimativa de máxima verossimilhança" para estimar o erro entre as saídas previstas e reais. Se a saída estimada para uma instância for superior a 50%, o modelo prevê a classe positiva; caso contrário, prevê a classe negativa, definindo assim o caráter binário da classificação.

2.3.2 Support Vector Machine (SVM)

O algoritmo SVM é projetado para encontrar um hiperplano ótimo que separa efetivamente os dados em classes distintas. Este algoritmo é caracterizado pelo seu foco em vetores de suporte, pontos de dados específicos que são essenciais para

definir a posição e orientação do hiperplano decisivo. A maximização da margem, a distância entre o hiperplano de separação e os vetores de suporte, é uma característica chave da SVM, refletida no conceito de "hard margin" (Prinzi et al., 2024).

Entretanto, em alguns casos, é necessário permitir certo erro de classificação para melhorar a capacidade de generalização do modelo, o que leva ao conceito de "soft margin". A gestão dessa flexibilidade é controlada pelo parâmetro de regularização C , que ajusta o trade-off entre maximizar a margem e minimizar o erro de treinamento. Um valor menor de C indica uma tolerância maior para com os erros de classificação durante o treinamento, favorecendo a generalização, enquanto um valor maior de C foca na precisão do modelo nos dados de treinamento, potencialmente às custas da generalização (Prinzi et al., 2024).

Nos casos em que os dados não são linearmente separáveis, o algoritmo SVM utiliza o truque do kernel para projetar os dados em uma dimensão mais alta, onde se tornam separáveis. Esta etapa é fundamental, pois a escolha do kernel adequado afeta diretamente a distribuição dos dados no novo espaço e, por consequência, o desempenho da classificação (Prinzi et al., 2024).

2.3.3 Redes Neurais Convolucionais (CNN)

Prinzi et al. (2024) explicam que as redes neurais convolucionais (CNNs) são essenciais na análise de imagens devido à sua capacidade de integrar a extração de características diretamente em seu processo de análise, tornando-as particularmente interessantes para aplicações em imagens médicas. A arquitetura de uma CNN é composta por camadas sequenciais que incluem camadas de convolução e de pooling. As camadas de convolução aplicam filtros ajustáveis que permitem à rede aprender a identificar características específicas, como texturas ou bordas, enquanto as camadas de pooling ajudam a reduzir a dimensionalidade dos dados, aumentando a eficiência do processo de aprendizado. Esse arranjo permite que as CNNs processem informações desde o nível mais básico até características complexas e abstratas, cruciais para a classificação eficaz de imagens.

2.3.4 K-Nearest Neighbors

A abordagem KNN é um dos métodos de classificação mais simples, nos quais o algoritmo encontra os k exemplos mais próximos no conjunto de treinamento para atribuir a classe aos novos dados. O processo de treinamento envolve o cálculo das distâncias entre os pontos de dados, e quando novos dados são introduzidos, essas distâncias precisam ser recalculadas. O algoritmo requer a definição de três hiperparâmetros principais: a cardinalidade do vizinho, que define quantos vizinhos serão verificados para a atribuição de classe, a métrica para estimar a distância entre os pontos vizinhos e a função de peso para atribuir um peso de acordo com a distância. O núcleo desse classificador depende principalmente da escolha da métrica para calcular a distância entre os exemplos testados e os exemplos de treinamento. (Prinzi et al., 2024)

2.3.5 Random Forest

Este algoritmo treina múltiplas árvores de decisão, cada uma considerando um subconjunto aleatório dos dados, e melhora a estabilidade e a precisão através de um mecanismo de votação das árvores. É útil em casos de dados ausentes e ruidosos, com a configuração do número de estimadores sendo um hiperparâmetro importante (Prinzi et al., 2024).

O estudo explora o uso desse algoritmo para treinar múltiplas árvores de decisão (DTs), utilizando uma técnica chamada bagging, que permite o treinamento de cada DT em uma porção aleatória do conjunto de dados. Esse método gera resultados variados para cada DT individual, pois elas são treinadas com dados e características diferentes. A agregação das previsões de todas as DTs através de um mecanismo de votação é o que confere ao RF sua robustez, melhorando a estabilidade e a acurácia do modelo. Um hiperparâmetro chave no RF é o número de estimadores, que é o número de DTs na floresta, e embora não haja uma regra geral para definir esse número, outro parâmetro importante é o número máximo de características usadas no treinamento de cada DT. O RF é considerado adequado para casos com dados ausentes ou com ruído.

CAPÍTULO 3 - REVISÃO DA LITERATURA

Nessa revisão de literatura discutem-se os avanços nas abordagens analíticas, incluindo o uso de séries temporais e a eficiência de alguns classificadores de machine learning, para fornecer um entendimento abrangente sobre estratégias adequadas de intervenção na fadiga relacionada a exercícios.

3.1 Tecnologias de Monitoramento

A importância e o impacto das tecnologias vestíveis na detecção da fadiga cognitiva são destacados por Varandas et al. (2022). Utilizando dispositivos *fNIRS* vestíveis junto com algoritmos de aprendizado de máquina, este estudo visa detectar automaticamente estados de fadiga cognitiva. As tecnologias vestíveis oferecem a vantagem de monitorar os pacientes de maneira não intrusiva, permitindo a coleta de dados em tempo real em ambientes naturais. Esse avanço abre caminho para monitoramentos cognitivos contínuos, facilitando intervenções personalizadas e mais efetivas.

No estudo, procedimentos experimentais foram conduzidos para induzir a fadiga cognitiva efetivamente, através de uma aula digital e tarefas cognitivas padrão. Através dos dispositivos *fNIRS*, os dados fisiológicos dos participantes foram coletados e, posteriormente, analisados com algoritmos de machine learning, alcançando uma precisão de classificação de aproximadamente 70,91%. Esses resultados evidenciam o potencial da combinação dos dispositivos vestíveis *fNIRS* com o aprendizado de máquina para uma detecção precisa e individualizada da fadiga cognitiva.

A adaptabilidade dessas tecnologias às dinâmicas individuais dos usuários, sem a necessidade de equipamentos complexos ou ambientes especializados, marca um avanço significativo para sua aplicação em cenários reais, como o e-learning, entre outros contextos de aprendizado. Esta abordagem não só melhora a eficácia do monitoramento da fadiga cognitiva, mas também suporta o desenvolvimento de intervenções personalizadas, otimizando o processo de

aprendizado e a produtividade, ao mesmo tempo em que minimiza o risco de sobrecarga cognitiva.

O estudo conduzido por Hayat et al. (2022) aborda o desafio do reconhecimento de atividades humanas em idosos, utilizando algoritmos de aprendizado de máquina e aprendizado profundo. Com o envelhecimento, a capacidade física e a autonomia para realizar tarefas diárias tendem a diminuir, afetando a saúde física e mental dos idosos. Diante disso, a pesquisa propõe um sistema de monitoramento assistido que emprega dados de acelerômetro e giroscópio coletados de smartphones para reconhecer atividades rotineiras, como se sentar, andar, subir escadas, entre outras.

O estudo destaca o papel crucial dos smartphones como dispositivos de monitoramento acessíveis e robustos, que, aliados a algoritmos como *K-Nearest Neighbors*, *Random Forest*, *Support Vector Machine*, *Artificial Neural Network*, e *Long Short-Term Memory* (LSTM), alcançam uma precisão notável na identificação de atividades. Especificamente, o modelo LSTM apresentou a melhor precisão, atingindo 95,04% de acurácia. Este desempenho exemplifica o potencial do uso de tecnologias vestíveis e de aprendizado de máquina para aprimorar o cuidado e o suporte aos idosos, promovendo uma maior independência e segurança.

3.2 Abordagens para detecção de fadiga

Hooda et al. (2022) oferecem uma revisão abrangente sobre métodos de detecção de fadiga utilizando técnicas de aprendizado de máquina, destacando a crescente prevalência da fadiga em um mundo em rápida transformação e a necessidade de abordagens eficazes para sua detecção. Eles introduzem e discutem métodos e avanços recentes na detecção de fadiga, categorizando as abordagens em modelos matemáticos, implementações baseadas em regras, aprendizado de máquina e aprendizado profundo. A revisão compara e contrasta vários algoritmos para identificar a abordagem mais promissora para a detecção de fadiga, destacando áreas para melhorias futuras.

Dentre as abordagens de detecção de fadiga, os métodos de aprendizado de máquina e aprendizado profundo apresentam-se como promissores, abrangendo o monitoramento de sinais eletroencefalográficos (EEG), detecção de bocejos, análise de músculos faciais, detecção de sonolência e identificação de pupilas, com o EEG

sendo particularmente notável pela sua eficácia na detecção de padrões de sono e, por consequência, na detecção de fadiga.

Por fim, a revisão conclui que aprendizado de máquina e aprendizado profundo podem ser úteis tanto na detecção quanto no diagnóstico da fadiga, potencializando o avanço do setor de saúde. O artigo apresenta uma revisão detalhada das descobertas de pesquisa relacionadas à detecção de fadiga, destacando o caminho para futuras inovações na área.

O estudo de Gao et al. (2023) investigou o impacto da fadiga induzida por corrida na distribuição da força plantar nos pés dominante e não dominante de corredores amadores. Utilizando medidas pedobarográficas, o estudo objetivou facilitar o reconhecimento automático da marcha fatigada por meio de modelos de rede neural convolucional (CNN) e rede neural de longo-curto prazo baseada em CNN (ConvLSTM). A coleta de dados da força plantar foi realizada antes e após um protocolo de indução de fadiga em corrida, usando uma placa de força *FootScan*, e os dados foram analisados com os modelos de aprendizado profundo implementados na biblioteca Keras do Python.

Os resultados demonstraram que, após a fadiga, ocorreu um aumento significativo da força na região do meio do pé anterior e do calcanhar durante a plantar bilateral, com uma diminuição da força na região média do pé no membro dominante. O modelo ConvLSTM mostrou desempenho superior (acurácia= 0.867, sensibilidade= 0.874 e especificidade= 0.859) na detecção da marcha fatigada em comparação com o modelo CNN (acurácia= 0.800, sensibilidade= 0.874 e especificidade= 0.718). Esses achados podem oferecer dados empíricos para avaliar fatores de risco associados a lesões por uso excessivo em um único membro, além de facilitar a detecção precoce da marcha fatigada.

A abordagem deste estudo, utilizando pedobarografia e modelos de aprendizado profundo, indica um caminho promissor para o monitoramento e a intervenção precoce na fadiga induzida por corrida, contribuindo para a prevenção de lesões e a otimização do treinamento de corredores amadores.

3.3 Séries Temporais na detecção de fadiga

O estudo de Hajifar et al. (2020) destaca a aplicação de métodos de séries temporais para prever a fadiga física, um passo essencial na ergonomia e na

segurança do trabalho. As séries temporais, que analisam dados ao longo do tempo para identificar padrões e prever eventos futuros, são particularmente úteis na detecção da fadiga, permitindo intervenções preventivas antes que a fadiga afete negativamente o desempenho e a segurança.

O estudo compara cinco modelos de previsão de séries temporais — métodos ingênuos, autorregressivos (AR), autorregressivos integrados de médias móveis (ARIMA), autorregressão vetorial (VAR) e modelo de correção de erro vetorial (VECM) — usando dados de percepção subjetiva de esforço (RPE) e dados de marcha de sensores vestíveis. O modelo VECM, que integra dados históricos de RPE e de sensores vestíveis, superou os demais modelos, fornecendo previsões precisas para até três períodos à frente, com um erro médio absoluto (MAE) inferior a 1,24 em todos os participantes.

A capacidade dos dados de sensores vestíveis de melhorar significativamente a precisão das previsões de fadiga destaca a importância dessas tecnologias na previsão da condição do trabalhador. O sucesso do modelo VECM em fornecer previsões precisas demonstra o potencial das séries temporais e dos sensores vestíveis em monitorar e intervir na fadiga antes que ela comprometa a segurança e o desempenho.

O estudo conduzido por Biró et al. (2024) explora o uso de Unidades de Medição Inercial (IMUs) e inteligência artificial para monitorar e otimizar ciclos de treinamento de atletas, visando equilibrar desempenho esportivo de alta performance com o controle adequado de fadiga e resistência. Este estudo destaca-se por sua abordagem inovadora na coleta e análise de dados multivariados de séries temporais, gerados por IMUs, para prever níveis de fadiga e ajustar as rotinas de treinamento de forma individualizada.

Utilizando IMUs acopladas a 19 atletas, os pesquisadores registraram aceleração triaxial, velocidade angular e orientação magnética ao longo de sessões repetidas, que incluíam corridas de ritmo constante e técnicas indutoras de fadiga. Dados brutos das séries temporais foram empregados para treinar um modelo de aprendizado de máquina supervisionado, baseado em características de domínio de frequência e tempo. Foram comparados os desempenhos de modelos *Random Forest*, *Gradient Boosting Machines* e redes LSTM, com um loop de feedback

ajustando o modelo em tempo real baseado em erro de previsão e estimativa de viés.

O modelo demonstrou alta precisão preditiva para fadiga, exibindo correlações significativas entre os níveis de fadiga previstos e os declínios observados no desempenho. As previsões de resistência possibilitaram ajustes de treinamento individualizados, sincronizados com os limiares fisiológicos dos atletas. Mecanismos de correção de viés se mostraram eficazes na minimização de erros de previsão sistemáticos. Adaptações em tempo real do modelo conduziram a estratégias de periodização de treinamento aprimoradas, reduzindo o risco de treinamento excessivo e melhorando o desempenho atlético geral.

O estudo conclui que o modelo assistido por IA utilizando dados multivariados de séries temporais gerados por IMU, é eficaz na análise de desempenho esportivo. O treinamento pode ser personalizado e constantemente alterado, pois o modelo prevê com precisão a fadiga e a energia. O modelo de IA pode prever efetivamente o início da fadiga antes que sintomas físicos se manifestem, permitindo intervenções oportunas para evitar treinamento excessivo e possíveis acidentes. Ele exibe uma boa capacidade de personalizar programas de treinamento de acordo com as reações fisiológicas de cada atleta, melhorando a eficácia geral do treinamento. Além disso, o estudo demonstrou a eficácia do modelo em monitorar o desempenho em tempo real, aprimorando a capacidade de tomada de decisão de treinadores e atletas.

CAPÍTULO 4 - MÉTODO DE PESQUISA

4.1 Caracterização da Pesquisa

Para alcançarmos nossos objetivos descritos anteriormente, iremos utilizar o método de experimentação utilizando as seguintes hipóteses:

- Hipótese Nula (H_0): Não é possível utilizar técnicas de aprendizado de máquina para prever a ocorrência de fadiga em idosos.
- Hipótese Alternativa (H_1): É possível utilizar técnicas de aprendizado de máquina para prever a ocorrência de fadiga em idosos.

Para isso iremos utilizar os algoritmos estado da arte na base descrita acima, onde iremos comparar as acurácias dos modelos e seus custos computacionais.

4.2 Método de Pesquisa

Para conseguir provar uma das hipóteses utilizando o método de experimentação, iremos seguir o seguinte protocolo:

Primeiramente, será feito uma análise exploratória da base onde será observado o comportamento do corpo humano ao decorrer do experimento, a fim de encontrar alterações que indiquem a possível ocorrência de fadiga. Além disso essa análise será útil para a próxima etapa do protocolo, onde pode-se visualizar quais queres tratamentos que deverão ser realizados na base antes do treinamento dos algoritmos de aprendizado de máquina.

Após a análise exploratória, será realizada os devidos tratamentos na base, como remoção de dados faltantes por meio da reconstrução do movimento realizado do ponto, normalização do movimento etc.

Com a base tratada, será separado em treino, teste e validação utilizando a técnica de K-Folds, onde será escolhida uma fração de treino, teste e validação (Ex.: 70%, 20% e 10% respectivamente) onde depois da validação será alternada as frações, podendo utilizar partes do teste ou validação no treino e vice-versa.

Com a base separada será treinado, testado e validado os algoritmos de aprendizado de máquina escolhidos onde iremos observar seus resultados e suas

métricas de avaliação de performance, como acurácia, erro médio quadrado e f1 score.

Com esses resultados, será feita uma análise crítica deles, para assim visualizar se foi possível provar uma hipótese proposta e responder o porquê foram esses os resultados encontrados.

CAPÍTULO 5 - VALIDAÇÃO DA PESQUISA CIENTÍFICA

Neste capítulo será detalhado a base que será utilizada para a validação em mais detalhes, será detalhado quais serão os parâmetros utilizados para a validação da pesquisa, as métricas que utilizaremos, os algoritmos que serão testados e as máquinas e softwares que serão utilizadas para realizar o experimento. Por fim será apresentado alguns testes já realizados com a base.

5.1 Base de Dados

A base de dados desse trabalho consiste em 20 candidatos idosos, 11 do sexo feminino e 9 do sexo masculino. Dos quais realizam exercício de se levantar e se sentar (exemplificado anteriormente na figura 1-1). Onde, em média, realizaram 243 repetições, onde o maior caso foi de 650 repetições e o menor caso foi de 35 repetições.

Em toda a nossa base, 15% dela corresponde a valores em branco, mas como muitos pontos se complementam. será possível realizar reconstrução desses dados faltantes utilizando outros pontos, além do próprio software utilizado para coleta, o OptiTrack, possuir funções que realizam exatamente essa reconstrução.

5.2 Validação da Pesquisa

O ambiente para a validação deverá ser um computador com qualquer SO que suporte Python e TensorFlow, também serão necessários o Professor Eduardo e Mestranda Rafaela para uma avaliação final dos resultados.

Para o início das validações do algoritmo de previsão a base já deverá estar anotada e o algoritmo treinado. Serão passados dados para a avaliação do algoritmo, que por sua vez deverá prever em que momento a fadiga deverá aparecer.

Se dará como finalizado a fase de validação quando os resultados obtidos estejam dentro dos limites desejados, como por exemplo: Acurácia, Erro médio quadrado etc.

Para a validação, será usada os 57 pontos para o treinamento, através dos algoritmos de séries temporais Regressão Logística, SVM, CNN, K-Nearest Neighbors e Random Forest e após a realização dos testes serão analisadas as métricas de: acurácia, erro médio quadrado, f1 score.

5.3 Testes Executados

Antes de realizar os testes na base de dados desse trabalho, foi demonstrado que ele possui vários dados faltantes, para tratar esses dados foi utilizado o algoritmo abaixo.

Quadro 5-1: Código utilizado para realizar tratar os dados faltantes Fonte: Os Autores

Algoritmo 1 Tratamento de dados Faltantes

```
primeiro = True
sem_na = []
cont = 0
nulls = False
anterior = 0
for j in data[i]:
    if pd.isna(j) :
        if primeiro:
            primeiro = False
            cont = 1
            nulls = True
            continue
        cont += 1
        continue
    if nulls:
        dif = (j - anterior) / (cont + 1)
        for k in range(cont):
            num = (anterior + ((k+1) * dif))
            sem_na.append(num)

        primeiro = True
        nulls = False
        cont = 0
    sem_na.append(j)
    anterior = j

if cont != 0:
    for _ in range(cont):
        sem_na.append(anterior)
```

Com os dados completos, foi realizado testes utilizando o ponto LFTC que como demonstrado no detalhamento da base de dados, continua sendo um ponto importante para realização dos primeiros testes com Machine Learning.

Nos testes realizados foi separado 70% da base para treino, 20% da base para validação e 10% da base para teste. E esses dados foram normalizados utilizando uma média simples.

Com os dados normalizados foi criada várias janelas de dados, das quais são:

- Janela 1 para 1 (utiliza o último valor para prever 1 valor no futuro)




Figura 5-1: Imagem representando janela 1 para 1 Fonte: https://www.tensorflow.org/tutorials/structured_data/time_series?hl=pt-br

- Janela 3 para 1 (utiliza os últimos 3 valores para prever 1 valor no futuro)




Figura 5-2: Imagem representando janela 3 para 1 Fonte: https://www.tensorflow.org/tutorials/structured_data/time_series?hl=pt-br

- Janela 24 para 24 (utiliza os últimos 24 valores para prever 1 valor no futuro do seu valor correspondente)

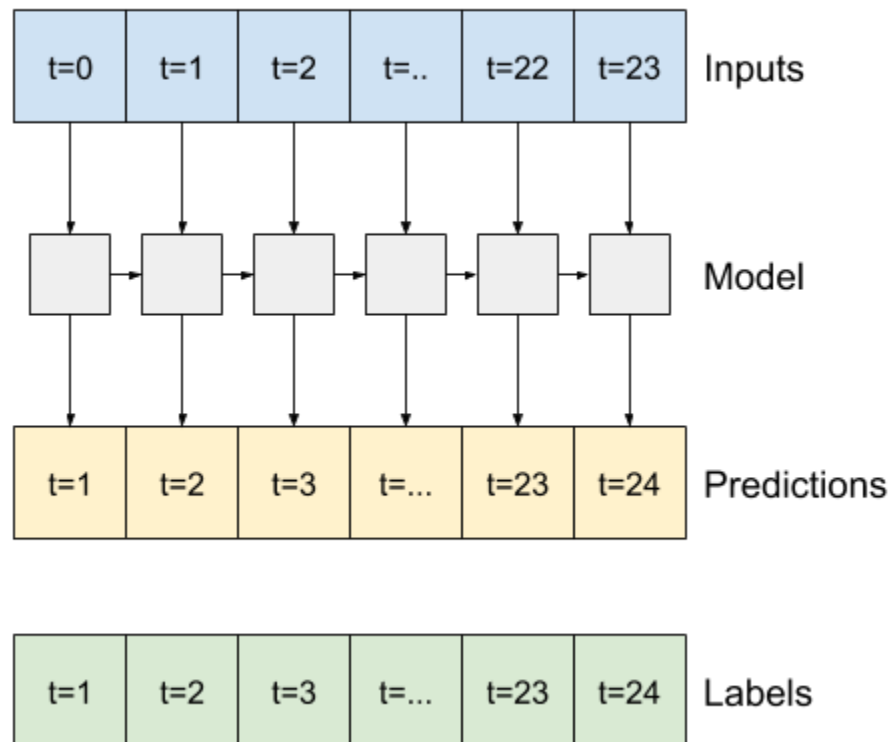


Figura 5-3: Imagem representando janela 24 para 24 Fonte: https://www.tensorflow.org/tutorials/structured_data/time_series?hl=pt-br

Com essas janelas foi testado os seguintes algoritmos de máquina:

- BaseLine: Retorna o valor passado como predição (janela 1 para 1)
- Modelo Linear (janela 1 para 1)
- Modelo Denso (janela 1 para 1)
- Modelo Denso Multi passo (janela 3 para 1)
- Rede Neural de Convolução (janela 3 para 1)
- Rede Neural Recorrente (janela 24 para 24)

Esses modelos apresentaram os seguintes resultados.

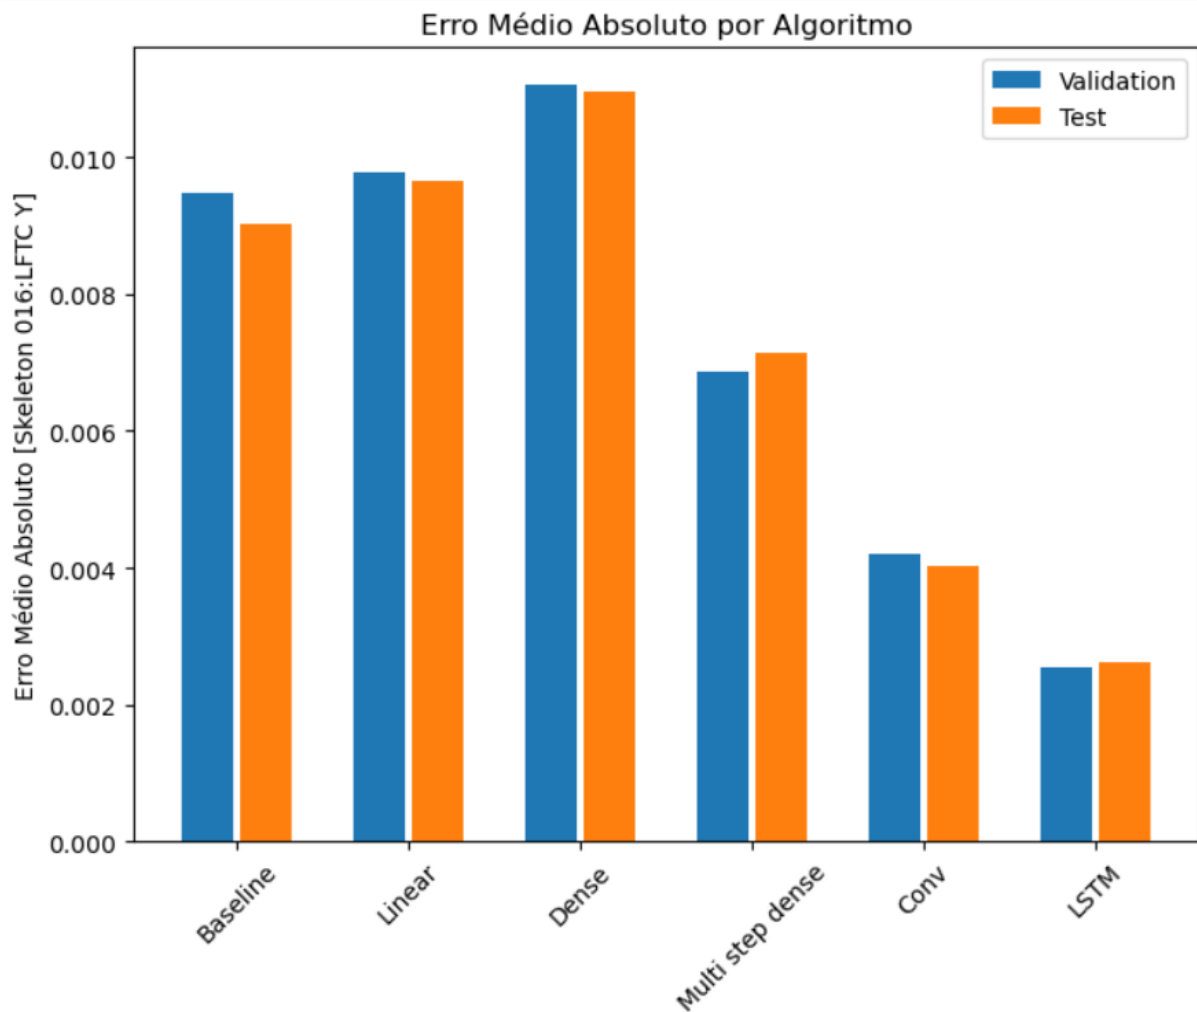


Figura 5-4: Resultado apresentado nos testes realizados Fonte: Os Autores

Com esses resultados podemos ver que o erro médio de todos os algoritmos foi bem baixo, o que mostra a eficiência desses algoritmos simples de conseguirem prever pontos no futuro somente olhando para um ponto e seus eixos.

O mais preocupante é a eficiência do BaseLine do qual somente retorna o último valor, mas ainda sim tem erro médio absoluto próximo a modelos lineares e densos, o que mostra a possibilidade de o problema desse trabalho poder ser resolvido por simples cálculos matemáticos, sem necessidades de redes neurais complexas. Contudo, como foi analisado somente um ponto, espera-se que essa proximidade com modelos mais complexos não será mantida quando for testado todos os pontos e for realmente procurado o objetivo desse trabalho, a fadiga.

CAPÍTULO 6 - INFORMAÇÕES DA PESQUISA

6.1 Cronograma

Para a organização desse trabalho, foi feito o cronograma de mês a mês destacando os objetivos gerais que temos que alcançar em cada mês para conseguir realizar este trabalho no tempo estipulado para ele.

Tabela 6-1. Planejamento após apresentação da Proposta. Fonte: os Autores

Mês	Objetivo Geral
Março	1. Construção do Cronograma 2. Início da Proposta do Trabalho
Abril	1. Finalização da Proposta do Trabalho. 2. Preparação para Apresentação 3. Reorganização de Pontos Faltantes na Proposta do Trabalho
Maió	1. Finalização da Visualização dos Pontos da Base e Excel para Anotação de Dados. 2. Início do Projeto de Pesquisa 3. Verificação da Efetividade das Anotações Realizadas
Junho	1. Finalização do Projeto de Pesquisa 2. Montagem de Primeiro Protótipo
Julho	1. Finalização de Pontos de Meses Anteriores
Agosto	1. Análise Exploratória da Base 2. Montagem dos primeiros Pipeline de Aprendizados de Máquina 3. Início da Escrita da Pesquisa Científica
Setembro	1. Rodada de Treino e Testes do Classificadores Escolhidos 2. Análise dos Resultados encontrados
Outubro	1. Finalização da Escrita da Pesquisa Científica 2. Preparação da Apresentação do Trabalho Final
Novembro	1. Finalização de Pontos de Meses Anteriores

Como mostrado na tabela, em março foi montado esse cronograma e seu deu início a essa proposta.

Em abril, é planejado finalizar essa proposta com as revisões do orientador, a montagem da apresentação junto com apresentações teste para preparar a equipe, por fim após a apresentação do trabalho e correções dos professores, será realizado as devidas revisões nesse trabalho.

Em maio, planeja-se finalizar a visualização dos pontos da base e dos Excel que serão utilizados pelos elaboradores da base para realizar a anotação dos dados, complementando sua informação. Após isso, será dado início Ao Projeto de Pesquisa.

Por fim será verificado se as visualizações criadas foram efetivas para anotações de dados e se é possível criar um protótipo do trabalho com as informações adquiridas.

Em junho, será finalizado o Projeto de Pesquisa onde também terá o protótipo necessário para essa entrega e será montado a apresentação com realização de apresentação teste com a equipe.

Em julho, será utilizado o tempo para finalizar quaisquer pontos que tenha ficado incompleto dos meses passados.

Em agosto, será realizado a análise exploratória onde nela procuraremos alcançar o primeiro objetivo específico desse trabalho, especificado na introdução. Com essa análise será montado as pipelines de pré-processamentos necessários para os algoritmos de aprendizado de máquina.

Por fim, será iniciado a escrita da Pesquisa Científica, principalmente, dos resultados da análise exploratória e os pré-processamentos que serão realizados.

Em setembro, será realizado as rodadas de treino e teste dos algoritmos de aprendizado de máquina e será analisado seus resultados para visualizar se foi alcançado o objetivo principal desse trabalho.

Em outubro, será finalizado a Pesquisa Científica, adicionando os resultados encontrados no mês anterior e as conclusões que forem encontradas desses resultados. Com a Pesquisa Científica finalizada, será montada a apresentação final desse trabalho com mais apresentações teste para preparação da equipe.

Em novembro, terá seu tempo utilizado para tópicos faltantes nos meses anteriores.

6.2 Riscos

Para que este trabalho seja finalizado sem problemas, foram detalhados abaixo os riscos desse projeto, onde detalhamos sua probabilidade, impacto, severidade, ações de prevenção e ações de contingência.

Tabela 6-2. Riscos do projeto. Fonte: os Autores.

Id	Descrição	P	I	S	Ação de Prevenção	Ação de Contingência
1	Falha na Classificação da Base	Baixa	Alto	3	Auxiliar na classificação da base e procurar	Utilizar algoritmos de aprendizado de máquina que possam

					mais pessoas para realizarem a anotação	realizar a detecção de mudança da série temporal ao invés de classificadores
2	Falta de Tempo	Baixa	Alta	3	Procurar separar as tarefas de forma igual para todos os integrantes, não criar cronogramas com muitas tarefas e programar períodos para finalizar tarefas pendentes	Procurar auxílio com outras pessoas que possam acelerar o processo e diminuir a necessidade de tempo
3	Falta de Conhecimento em Classificadores de Series Temporais	Baixa	Baixa	1	Procurar outros trabalhos que já utilizaram esses classificadores e procurar ler os tutoriais disponibilizados na internet	Procurar auxílio com outras pessoas que já tenham trabalhado com esses classificadores e possam auxiliar no trabalho
4	Algoritmos de Aprendizado de Máquina necessitando de mais tempo do que esperado para seu treino e teste	Médio	Médio	4	Procurar simplificar o que for possível da rodada de treino e teste a ser realizada dos algoritmos	Procurar auxílio com outras pessoas que possuam máquinas mais potentes e que tenham interesse em auxiliar no trabalho.

Legenda P: probabilidade (alta, média, baixa)

I: impacto (alto, médio, baixo)

S: severidade ($S=P \cdot I$)

O risco de falha na classificação na base, pode ocorrer no caso de não for concluída a classificação dos dados ou houver classes incorretas na base. As chances desse risco ocorrer são baixas visto que as pessoas que estão responsáveis pela ação são bem capacitadas para o serviço, mas para evitar isso, a equipe irá auxiliar no máximo possível e se visto necessário encontrar mais pessoas para auxiliar. Caso ocorra essa falha pode-se utilizar de algoritmos de aprendizagem de máquina para realizar a classificação. Caso não seja concluída a classificação existe um alto risco para com o projeto, pois sem os dados categorizados, não será possível aplicar os métodos de detecção de séries temporais.

Os riscos por falta de tempo, pode ocorrer pelo grupo não conseguir alcançar os prazos existentes devido à falta de tempo dos membros da equipe ou ao atraso de alguma atividade. Devido há como está a situação atual do projeto, é baixa a chance de ocorrer o atraso, já que foi feito de modo mais balanceada a separação de tarefas e reservado tempo para tarefas faltantes no cronograma. Caso ocorra a

falta de tempo será buscado mais pessoas que possam ajudar o desenvolvimento das atividades. O impacto de falta de tempo é grande, visto que isso afeta diretamente a conclusão do projeto.

Outro possível risco é a falta de conhecimento da equipe em relação aos classificadores de séries temporais, que é considerado baixo, visto que já está marcado no planejamento do grupo estudar sobre o assunto. Caso a dificuldade se mantenha após esse estudo programa, será buscado pessoas que já tenham trabalhado com os algoritmos para auxiliar no desenvolvimento. Foi considerado baixo este risco, já que existem diversas fontes para o grupo estudar sobre o assunto.

Existe também o risco de os algoritmos de aprendizado de máquina levarem mais tempo do que o imaginado para concluírem seus cálculos, que foi previsto como mediano, devido ao tamanho da base ser extensa, mas o patamar da tecnologia de hoje facilita ainda que se tenha uma base grande para trabalhar. Contudo para evitar será realizada a simplificação de alguns algoritmos durante a rodada de treino e testes. Caso ainda ocorra atrasos, será buscado auxílio de pessoas que possuam computadores com uma maior potência de cálculo e estejam dispostas a ajudar disponibilizando o equipamento. No caso de os algoritmos levarem mais tempo que esperado será gerado um impacto de proporções moderadas, visto que causará atrasos pequenos.

REFERÊNCIAS BIBLIOGRÁFICAS

MOTA, Dálete Delalibera Corrêa de Faria; CRUZ, Diná de Almeida Lopes Monteiro da; PIMENTA, Cibele Andrucio de Mattos. Fadiga: uma análise do conceito. *Acta Paulista de Enfermagem*, v. 18, p. 285-293, 2005.

ADÃO MARTINS, Neusa R.; ANNAHEIM, Simon; SPENGLER, Christina M.; ROSSI, René M. (2021). Fatigue Monitoring Through Wearables: A State-of-the-Art Review. *Frontiers in Physiology*, v. 12, artigo 790292. Disponível em: <https://doi.org/10.3389/fphys.2021.790292>. Acesso em: 07 abr. 2024.

GAO, Z.; XIANG, L.; FEKETE, G.; BAKER, J. S.; MAO, Z.; GU, Y. (2023). A Data-Driven Approach for Fatigue Detection during Running Using Pedobarographic Measurements. *Applied Bionics and Biomechanics*. Disponível em: <https://doi.org/10.1155/2023/7022513>. Acesso em: 08 abr. 2024.

HAJIFAR, S.; SUN, H.; MEGAHED, F. M.; JONES-FARMER, L. A.; RASHEDI, E.; CAVUOTO, L. A. (2020). A Forecasting Framework for Predicting Perceived Fatigue: Using Time Series Methods to Forecast Ratings of Perceived Exertion with Features from Wearable Sensors. *Applied Ergonomics*. Disponível em: <https://doi.org/10.1016/j.apergo.2020.103262>. Acesso em: 08 abr. 2024.

HAYAT, A.; MORGADO-DIAS, F.; BHUYAN, B.P.; TOMAR, R. Human Activity Recognition for Elderly People Using Machine and Deep Learning Approaches. *Information*, v. 13, p. 275, 2022. Disponível em: <https://doi.org/10.3390/info13060275>. Acesso em: 07 de abr. 2024.

HOODA, R.; JOSHI, V.; SHAH, M. (2022). A comprehensive review of approaches to detect fatigue using machine learning techniques. *Chronic Diseases and Translational Medicine*, 8: 26–35. Disponível em: <https://doi.org/10.1016/j.cdtm.2021.07.002>. Acesso em: 08 de abr. de 2024.

MURRAY, C.; CHAURASIA, P.; HOLLYWOOD, L.; COYLE, D. (2022). A Comparative Analysis of State-of-the-Art Time Series Forecasting Algorithms. Disponível em: <https://ieeexplore.ieee.org/document/10216678>. Acesso em: 07 abr. 2024.

VARANDAS, R.; LIMA, R.; BERMÚDEZ I BADIA, S.; SILVA, H.; GAMBOA, H. (2022). Automatic Cognitive Fatigue Detection Using Wearable fNIRS and Machine Learning. *Sensors*, v. 22, n. 11, p. 4010. Disponível em: <https://doi.org/10.3390/s22114010>. Acesso em: 07 abr. 2024.

BIRÓ, A.; CUESTA-VARGAS, A.I.; SZILÁGYI, L. (2024). AI-Assisted Fatigue and Stamina Control for Performance Sports on IMU-Generated Multivariate Times Series Datasets. *Sensors*, 24, 132. Disponível em: <https://doi.org/10.3390/s24010132>. Acesso em: 08 abr. 2024.

PRINZI, F.; CURRIERI, T.; GAGLIO, S.; VITABILE, S. (2024). Shallow and Deep Learning Classifiers in Medical Image Analysis. *European Radiology Experimental*, 8(26). Disponível em: <https://doi.org/10.1186/s41747-024-00428-2>. Acesso em: 13 abr. 2024.

ZHANG, C.; SJARIF, N. N. A.; IBRAHIM, R. (2023). Deep learning models for price forecasting of financial time series: A review of recent advancements: 2020-2022. Advanced Informatics Department, Universiti Teknologi Malaysia. Disponível em: <https://arxiv.org/abs/2305.04811>. Acesso em: 28 maio 2024.

He, K.; Yang, Q.; Ji, L.; Pan, J.; Zou, Y. (2023). Financial Time Series Forecasting with the Deep Learning Ensemble Model. Mathematics, 11(4), 1054. Disponível em: <https://doi.org/10.3390/math11041054>. Acesso em: 28 maio 2024.

LI, Zhe; QI, Shiyi; LI, Yiduo; XU, Zenglin. Revisiting Long-term Time Series Forecasting: An Investigation on Linear Mapping. Harbin Institute of Technology, Shenzhen, 2023. Disponível em: <https://github.com/plumprc/RTSF>. Acesso em: 28 maio 2024.

GLOSSÁRIO

APÊNDICE A – TÍTULO DO APÊNDICE A

[OptiTrack Documentation | v3.1 | EXTERNAL OptiTrack Documentation](#) -

Documentação do Programa OptiTrack